

一种基于多级信息融合技术的系统故障诊断方法

刘宜平 沈毅 童树鸿 刘志言

哈尔滨工业大学控制工程系, 150001

摘要 采用多级信息融合思想, 利用系统故障症状的分散性, 提出了一种新的系统故障诊断方法。首先, 我们采用多传感器同源数据融合来保证量测信号的准确可靠; 然后, 利用同一故障在系统中的不同表现症状, 采用模糊积分融合, 融合输出为相对应的故障诊断结果。最后对燃气轮机的多部位故障诊断进行了仿真研究, 结果较为理想。

主题词 信息处理 故障诊断 模糊数学 系统可靠性

中图分类号: TP18

An Approach to Fault Diagnosis Based on Hierarchical Information Fusion

Liu Yiping Shen Yi Tong Shuhong Liu Zhiyan

Dept. of Control Engineering, Harbin Institute of Technology, 150001

Abstract In this paper, we propose a novel approach to fault diagnosis based on hierarchical information fusion. First, we use the same source data fusion to confirm the reliability and accuracy of the measured signals. Then, we adopt multiple neural networks as fault classifiers to obtain the local decisions. Furthermore, we present a method for decision fusion based on fuzzy integral in which the relative importance of the different individual network is considered. Finally, we apply the approach to a turbine system and the experimental results show its good performance.

Keywords Information processing Fault diagnosis Fuzzy mathematics System reliability

1 引言

系统信号的检测一直是进行系统建模诊断等信号处理的瓶颈, 而目前量测精度较高的传感器一般价格昂贵, 难以广泛应用, 而价格低廉的传感器则精度较差, 传感器本身的误差将会给量测信号带来污染。由于多传感器系统能对各种信息进行综合处理, 因而可以使量测信息在准确性、可靠性及完备性等方面较其中任一单传感器有明显提高^[1]。本文提出了用价格便宜的多传感器替代单一传感器进行系统信号量测, 提高了量测信号的真实度, 为系统的正确诊断打下坚实的基础; 同时, 因为系统是一个有机的整体, 某一部位的故障将通过传播表现为系统整体的某一症状, 因此通过对不同部位信号的融合, 可以更合理地利用系统的信息做到更为准确的诊断。又因为诊断是依据系统不同部位分散信息进行的, 因而, 误诊的风险较小。

在故障诊断领域, 人类的经验尤其重要, 一些复杂系统的故障, 操作人员可以根据经验从某些症状中综合判断出该故障。而传统的特征信息融合算法不管环境如何变化, 只能

平均地利用各个传感器的信息。本文通过各个神经网络分类器得到当前系统归属于不同故障状态的可能性, 然后采用模糊积分融合方法, 将环境信息和语言信息引入到融合系统, 提高了融合效率与适应性。

2 多传感器同源信息综合

信息融合本身的特别困难就在于多个传感器数据的不确定性处理。如果将正确数据与不正确或是有偏差的数据联合在一起进行融合, 特别是在数据的不确定性和变化未知的情况下, 融合后的效果可能比单个传感器更差。因而对待融合数据的预处理就显得十分重要, 本层的作用就是为下一级的各个神经网络分类器提供较为准确的输入信息。在融合前我们采用模糊聚类技术进行融合数据的预处理分类, 以剔除明显不合理的传感器输出数据。同源信息融合算法与结构详见文献[2]。

3 多输出神经网络分类器

为了便于对网络性能进行评估, 同时使网络结构清晰简

收稿日期: 2000-01-02 修订日期: 2000-06-26

基金项目: 国家自然科学基金资助课题(69904004)

作者简介: 刘宜平(1974-), 博士, 主要研究方向为智能信息处理, 故障诊断。

单, 我们采用多输出四层前馈神经网络作为故障分类器。网络结构如图 1 所示。前三层网络的各节点函数均采用 Sigmoid 函数, 为了统一度量, 引入归一化层, 该层的节点函数为 $O_i =$




图 1 神经网络分类器

$I_i / \sum_{i=1}^m I_i$, 它保证了神经网络

分类器的输出满足 $0 \leq O_i \leq 1$ 且 $\sum_{k=1}^m O_i = 1$ 。网络的输入变量为经过同源信息融合后的系统各部位量测信号, 每一个输出节点代表着系统某种故障。其输出为在该神经网络分类器作用下, 当前系统属于各个故障状态的可能性, 也即

$$O_i = f \left\{ \sum_{k=1}^q W_F^k \cdot f \left\{ \sum_{j=1}^n W_C^k \cdot I_j \right\} \right\} \setminus \sum_{i=1}^m f \left\{ \sum_{k=1}^q W_F^k \cdot f \left\{ \sum_{j=1}^n W_C^k \cdot I_j \right\} \right\}$$

其中 f ——Sigmoid 函数; n ——网络输入节点个数; q ——隐层节点个数; W_C^k ——第 k 个隐层节点与第 j 个输入节点之间的连接权值; W_F^k ——第 i 个输出层节点与第 k 个隐层节点之间的连接权值, $i = 1, 2, \dots, m$, m ——输出节点个数。每个神经网络输入的划分, 可依据使每个分类器识别正确率最高的原则, 根据具体系统量测信号的情况或根据经验加以确定。例如, 为了提高对某些后果严重故障的检测敏感性, 需要提高融合的精度, 可将该故障的主要症状信号作为每个神经网络分类器的输入。同时, 为了提高训练速度, 改进网络权值的分布, 应使输入信号对网络的影响作用均衡。文中我们对所有网络输入进行一致性处理, 具体办法为对不同的信号进行归一化。

4 模糊积分信息融合

Sugeno 将经典的概率测度进行了推广, 提出了模糊测度与模糊积分的概念, 它具有考虑多源信息的重要程度进行融合的能力。文中, 我们采用 g_λ 模糊测度, 定义如下: 设 $P(X)$ 表示有限集合 $X = \{x_1, x_2, \dots, x_n\}$ 上的子集合全体。对于任意 $A, B \in P(X)$, 若映射 $g_\lambda: PX \rightarrow [0, 1]$ 满足条件:

(1) $g_\lambda(X) = 1$; (2) 当 $A \cap B = \emptyset$ 时, 有 $g_\lambda(A \cup B) = g_\lambda(A) + g_\lambda(B) + \lambda \cdot g_\lambda(A) \cdot g_\lambda(B)$; (3) $\lambda > -1$ 。则称为 g_λ 模糊测度。映射 $x_i \rightarrow g^i = g_\lambda(\{x_i\})$ 称为模糊密度函数, g^i 称为模糊密度。假设 $A = \{x_{i_1}, x_{i_2}, \dots, x_{i_m}\} \in X$, 则有

$$g_\lambda(A) = \sum_{j=1}^n g^j + \lambda \sum_{j=1}^{m-1} \sum_{k=j+1}^m g^j g^k + \dots + \lambda g^{i_1} \dots g^{i_m} \\ = \left[\prod_{x_i \in A} (1 + \lambda g^i) - 1 \right] \setminus \lambda$$

其中, λ 可以通过求解方程 $g_\lambda(X) = 1$ 得到, 它等价于求解方程

$$\lambda + 1 = \prod_{i=1}^n (1 + \lambda g^i) \quad (1)$$

对于一个固定的集合 $\{g^i\}$, $0 < g^i < 1$, 唯一存在 $\lambda \in (-1, +\infty)$, 且 $\lambda \neq 0$ 满足方程 (1)^[3]。基于模糊测度的定义, Sugeno 还提出了模糊积分的概念。令 $X = \{x_1, x_2, \dots, x_n\}$ 是一个有限集合, h 为 X 上的模糊子集, 它完成映射 $h: X \rightarrow [0, 1]$, g 为 X 上的模糊测度, A 为 X 中的子集合, 则称 $\mu(A) = \int_A h(\cdot) \circ g(\cdot) = \max_{E \subset A} [\min_{x \in E} h(x), g(E)]$ 为 h 在 A 上关于 g 的模糊积分。假设 $h(x_1) \geq h(x_2) \geq \dots \geq h(x_n)$, 则 X 上关于模糊测度 g 的模糊积分 e 的计算公式为

$$e = \max_{i=1}^n [\min(h(x_i), g(A_i))] \quad (2)$$

其中 $A_i = \{x_1, x_2, \dots, x_i\}$ 。当 g 为 g_λ 模糊测度时, 求解 $g(A_i)$ 的递推公式为

$$\begin{cases} g(A_1) = g(\{x_1\}) = g^1 \\ g(A_i) = g^i + g(A_{i-1}) + \lambda g^i g(A_{i-1}) \quad 1 < i \leq n \end{cases} \quad (3)$$

因此, 当使用 g_λ 模糊测度计算模糊积分时, 仅需模糊密度的知识, 第 i 个密度值 g^i 可以解释为信息 x_i 的重要程度。文中我们假定系统有 m 种故障状态 $F = \{FS_1, FS_2, \dots, FS_m\}$; 共有 c 个神经网络分类器 $N = \{NN_1, NN_2, \dots, NN_c\}$, 则令 $h_k: N \rightarrow [0, 1]$ 为各个神经网络故障分类器关于当前系统状态与故障类型 FS_k 之间关系的局部决策, 它实际为各子神经网络第 k 节点的输出值, 是当前系统隶属于系统第 k 种故障的可能性。然而, 由于各个神经网络样本训练、网络输入的不同, 以及不同的故障在系统不同部位症状体现程度的强弱也有差异, 因而每一个神经网络故障分类器对不同的故障识别正确程度也有较大的波动, 也即不同神经网络信息的重要程度是不同的, 并且随着不同的故障而变化。为了提高融合效率, 将此信息的重要程度考虑进去是十分必要的, 这也是本文采用模糊积分方法进行融合的主要原因。在这里, 我们将各个神经网络信息的重要程度作为模糊积分中的各个模糊密度值。通过将各个训练好的神经网络分类器分别独立进行在不同故障下的样本识别检验, 记录每个神经网络对各个故障的正确识别率作为该网络对各个故障分类的信息重要程度。在检验中我们采用 \max 算子作为评判依据, 也即在某样本下对网络的多个输出取最大值作为识别输出。需要指出的是, 分类器的信息重要程度也可根据实际应用情况由专家知识确定。在进行诊断时, 对各神经网络分类器的输出值同样进行 \max 运算, 以完成局部决策。完整的融合步骤如下:

(1) 确定模糊密度值 g^i 和根据各神经网络分类器的输出, 进行局部决策, 计算出 h_k ; (2) 由式 (1) 计算 λ 值; (3) 由式 (3) 计算 g_λ 模糊测度; (4) 由式 (2) 计算最终的模糊积分值。

将融合结果作为诊断输出。完整的诊断策略结构图如图 2 所示。

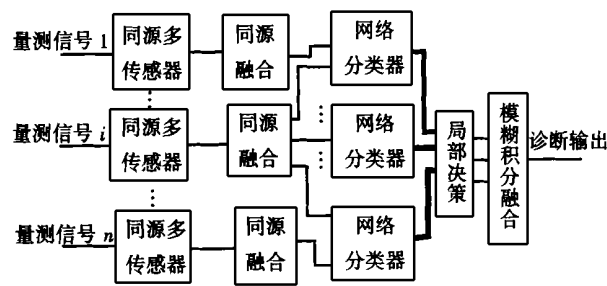


图 2 诊断系统结构框架图

5 仿 真

我们采用某燃气轮机的故障诊断进行仿真研究。故障类型为燃料管泄漏故障 f_1 、高压燃气轮机传动故障 f_2 、低压燃气轮机传动故障 f_3 。量测信号为燃油阀门开度 μ 、燃料室出口温度 T_O 、高压燃气轮机转速 n_1 、低压燃气轮机转速 n_2 以及燃烧室内压力 P 。分别由 μ 、 T_O 、 n_1 、作为神经网络分类器 1 的输入； T_O 、 P 、 n_2 作为神经网络分类器 2 的输入； μ 、

T_O 、 P 作为神经网络分类器 3 的输入。在各个故障状态下各选取 50 个样本再加上系统正常状态下 50 个样本共计 200 个样本对各个神经网络分类器进行训练, 训练采用 BP 算法, 网络训练目标为 0.1。于是, 系统状态 $F = \{FS_1, FS_2, \dots, FS_m\} = \{n, f_1, f_2, f_3\}$, 子网络分类器为 $N = \{NN_1, NN_2, \dots, NN_c\} = \{NN_1, NN_2, NN_3\}$ 。然后选用每一故障状态下 200 个样本进行识别检验, 用以确定每个网络分类器对各个故障的正确识别率, 它是各网络输出的置信度, 在模糊积分融合中它将解释为模糊密度值 g^j , 见表 1。采用第 4 节中的融合步骤, 根据当前样本下各子网分类器的输出值 h_k , 进行融合仿真, 部分仿真结果如表 2 所示。从仿真结果可以看出, 通过模糊积

表 1 各分类器输出置信度

分类器 状态	NN_1	NN_2	NN_3
故障 1	0.634 8	0.573 9	0.791 0
故障 2	0.951 0	0.348 1	0.371 0
故障 3	0.337 6	0.918 9	0.350 6
正 常	0.457 0	0.418 8	0.493 1

表 2 模糊积分融合结果

样本 序号	系统实 际状态	输出类别	NN_1	NN_2	NN_3	模糊积分	λ
1	故障 1	故障 1	0.844 2	0.804 5	0.981 0	—	—
		故障 2	0.043 2	0.052 1	0.011 2		
		故障 3	0.032 0	0.067 3	0.004 5		
		正常	0.080 6	0.076 1	0.003 3		
		局部决策	0.844 2(f_1)	0.804 5(f_1)	0.981 0(f_1)	0.844 2(f_1)	—0.957 0
2	故障 2	故障 1	0.007 9	0.033 2	0.009 1	—	—
		故障 2	0.872 3	0.672 0	0.597 9		
		故障 3	0.103 2	0.021 4	0.194 3		
		正常	0.016 6	0.273 4	0.198 7		
		局部决策	0.872 3(f_2)	0.672 0(f_2)	0.597 9(f_2)	0.872 3(f_2)	—0.964 8
3	故障 3	故障 1	0.097 3	0.001 4	0.019 8	—	—
		故障 2	0.113 2	0.018 7	0.314 5		
		故障 3	0.423 8	0.970 6	0.573 4		
		正常	0.365 7	0.009 3	0.092 3		
		局部决策	0.423 8(f_3)	0.970 6(f_3)	0.573 4(f_3)	0.918 9(f_3)	—0.935 4
4	故障 2	故障 1	0.013 5	0.159 2	0.134 0	—	—
		故障 2	0.878 2	0.091 0	0.543 0		
		故障 3	0.008 4	0.358 4	0.245 9		
		正常	0.099 9	0.391 4	0.077 1		
		局部决策	0.878 2(f_2)	0.391 4(n)	0.543 0(f_2)	0.878 2(f_2)	—0.970 9
5	故障 1	故障 1	0.910 1	0.523 5	0.391 1	—	—
		故障 2	0.014 8	0.244 9	0.102 3		
		故障 3	0.053 7	0.111 9	0.503 2		
		正常	0.021 4	0.119 7	0.003 4		
		局部决策	0.910 1(f_1)	0.523 5(f_1)	0.503 2(f_3)	0.634 8(f_1)	—0.818 2
6	正常	故障 1	0.140 1	0.053 7	0.020 7	—	—
		故障 2	0.293 7	0.023 5	0.033 7		
		故障 3	0.321 0	0.098 9	0.133 3		
		正常	0.245 2	0.823 9	0.812 3		
		局部决策	0.321 0(f_3)	0.823 9(n)	0.812 3(n)	0.804 1(n)	—0.522 0

分融合, 无论各分类器局部决策信息是否一致, 均可以做到对系统各种状态的正确识别。在样本 4、样本 5 中, 可以看出融合的结果好坏与各神经网络的局部决策输出有很大关系, 样本 4 中, 融合的决策输出值并没有受到不一致的局部决策信息的影响; 而在样本 5 中, 虽然最终的融合结果依然识别正确, 但是决策输出值

却因不一致信息影响有较大下降。这是因为神经网络分类器 1 对故障 2 的正确识别率较高, 而对故障 1 的正确识别率较低的原因。因此, 提高各分类器的置信度, 改进各神经网络的分类性能, 将是提高融合效率的关键。这可以通过训练样本的选择、处理、训练学习算法的改进等措施来进行。模糊积分融合值的改变, 体现了各个子网分类器不同的影响作用, 其值的下降恰恰是对当前系统状态识别诊断情况的真实反映。例如, 样本 3、样本 5 等经过模糊积分融合后的结果数值要低于对三个局部决策简单取 max 的值。但是如果不考虑其物理意义, 仅仅从纯数值的大小看, 是不能说明方

法效果的优劣的。因为一个置信度较低的网络, 其对系统当前状态误识别的可能就越大, 即使其输出值较高, 也未必能如实反映系统当前的真实状态。对各局部决策进行简单的 max 合成, 仅考虑了各子网络的输出值, 而并未考虑各子网络的输出置信度高低, 这显然是不合理的, 因而其效果难以评估。经过类似的计算, 我们分别对燃气轮机三种故障各 200 个样本进行识别诊断, 正确率分别达到 94.54%、97.23% 和 95.76%, 效果显著。

6 结 论

本文提出了一种采用多级融合策略的故障诊断方法。它充分利用了系统故障症状的分散性以及各个神经网络分类器局部决策信息的重要程度, 通过采用模糊积分决策融合, 达到了较理想的诊断效果。该方法适于系统的各种类型故障诊断, 且具有一定的容错能力, 因而具有较好的应有前景。

参 考 文 献

- 1 Luo Ren C, Kay Michael G. Multisensor Integration and Fusion for Intelligent Machines and Systems. Ablex Publishing Corporation, Norwood, New Jersey, USA, 1995.
- 2 刘宜平, 沈毅, 刘志言. 信息融合的模糊网络模型与算法研究. 机器人, 1999, 21: 175~179.
- 3 Tahanib, Kollar J M. Information Fusion in Computer Vision Using the Fuzzy Integral. IEEE Trans. SMC, 1990, 20(3): 733~741.
- 4 Sung B C, Kim Jin H. Multiple Network Fusion Using Fuzzy Logic. IEEE Trans. NN, 1995, 6(2): 497~501.
- 5 何友, 彭应宁等. 多传感器数据融合模型综述. 清华大学学报, 1996, 36(9): 14~20.
- 6 黎湘, 郁文贤等. 决策层信息融合的神经网络模型与算法研究. 电子学报, 1997, 25(9): 117~120.
- 7 敬忠良, 杨永胜等. 基于模糊神经网络的特征信息融合. 控制与决策, 1997, 12(5): 585~588.
- 8 孙红岩, 毛士艺. 多传感器目标识别的数据融合. 电子学报, 1995, 23(10): 188~193.
- 9 刘源, 谢维信等. 基于多传感器多目标特征信息的模糊数据关联算法. 系统工程与电子技术, 1998, 20(12): 18~23.

(上接第 32 页)

- 8 Wolf A, Swift J B, Swinney H L, et al. Determining Lyapunov Exponents from a Time Series. Physica D 16, 1985: 285.
- 9 袁坚, 肖先赐. 淹没在噪声中的混沌信号最大李雅普诺夫指数的提取. 电子学报, 1997, 25(10): 134.
- 10 Takens F. Detecting Strange Attractors in Fluid Turbulence. In Dynamical System and Turbulence, eds. D Rand and L. S. Young, Springer, Berlin, 1981.
- 11 Grassberger P, Procaccia I. Measuring the Strangeness Attractors. Physica D 9, 1983: 189.
- 12 Casdagli M. Nonlinear Prediction of Chaotic Time Series. Physica D 35, 1989: 335.
- 13 郭宇春, 孙连举, 戴宇礼等. 遗传算法及其应用. 系统工程与电子技术, 1998, 20(7): 59~62.