

学校代码: 10246

学 号: 022021040

復旦大學

硕 士 学 位 论 文

同源多传感器加权数据融合算法的研究

院 系: 信息科学与工程学院

专 业: 电路与系统

姓 名: 杨惠娟

指 导 老 师: 张建秋 教授

完 成 日 期: 2005 年 5 月 26 日

## 摘要

在工业应用中常用一组传感器对同一个被测量目标在一个过程的不同位置进行测量。然而由于每个传感器位于过程的不同位置，它们将不同程度的受到噪声的干扰，为了从被噪声干扰的多传感器测量值中获得更准确的测量结果，需要进一步研究多传感器的融合理论。

多传感器数据融合系统的关键在于如何充分利用各个传感器的信息，得到对被测参数的最优估计。本文主要研究了以加权的方式进行多传感器数据融合的方法，即研究如何对每个传感器进行加权，从而得到对被测参数最优估计的方法。

为此本文在介绍了多传感器数据融合技术的基础上，首先研究了基于奇异值分解的数据融合算法，通过对传感器测量值构成的矩阵进行奇异值分解，利用每个传感器测量值所对应的奇异值，可以估计出对每个传感器权值的最优估计，从而在不要任何先验知识的条件下，可仅由多传感器的测量值，利用提出的算法得到在最小均方误差意义下的被测参数的最优估计。此外，在许多工业过程中，人们利用多传感器测量同一过程参数以控制该参数在过程中的不同位置能根据需要进行合理分布。此时人们希望利用多传感器融合的测量结果，对每一个传感器的测量数据进行重建，以获得对每一个传感器的测量结果进行更为准确的估计。为此，本文进一步研究了基于小波降噪和数据融合的传感器数据重建算法，仿真和实验结果都说明提出算法是有效的。最后，研究了非线性动态系统的状态融合问题，研究了加权无气味卡尔曼滤波（UKF）方法，研究表明无气味卡尔曼滤波能克服了扩展卡尔曼滤波（EKF）在状态融合估计中的不足，可以得到了更准确的状态融合估计结果。

**关键词** 多传感器系统，数据融合，奇异值分解，UKF

## Abstract

In industrial applications, the multiple sensors are often used to measure the same process parameter at different locations of a process. In this way, the sensors could be suffered from the different noise and external disturbances. In order to get a more accurate description of the process parameters, the methods of multi-sensor data fusion are required to study further.

It is understood that the key element of a multi-sensor data fusion system is how to fuse the information from different sensors to get a optimum estimate about the measured parameters. This thesis will mainly focus on the weighted multi-sensor data fusion algorithm. Namely, we will study how to weight the measurements of the different sensors from a multi-sensor system so that the optimum estimate of the measured parameters can be obtained.

After the state of arts of multi-sensor data fusion technology is introduced, a SVD-based multi-sensor data fusion algorithm is presented. The weights for each sensor in a multi-sensor system can be estimated according to the singular values of a matrix constructed by the outputs of the sensors in the system without any other knowledge is required. With these weights, the optimal fusion estimate of a measured parameter can be obtained in terms of the minimum mean square error. Furthermore, there are many industrial processes which are needed to reasonably distribute the measured parameter on a process. At this time, to obtain a more accurate estimate for each sensor, it is desirable to be able to reconstruct the output of each sensor based on the fusion result from a multi-sensor fusion algorithm. The wavelet-based denoising and the multi-sensor data fusion algorithms are combined to do that. Both simulation and experiment results show that the proposed method is effective. Finally, the state fusion problem of a

nonlinear dynamical system with multi sensors is considered, a weighted Unscented Kalman Filter (UKF) method is proposed. The simulation results show that the proposed UKF state fusion method is outperform to the Extended Kalman Filter (EKF) ones.

**Keywords**      **Multi-sensor System, Data Fusion, Singular Value Decomposition, Unscented Kalman Filter**

## 第1章 绪论

### 1.1 课题背景

人类社会经历了农业、工业社会后进入了信息化社会。生活在当今信息化社会里，人们不得不承认在我们周边的“信息场”发生的两个重大变化：一是信息空间的结构越来越复杂，信息源所覆盖的空间越来越大，信息的种类也越来越繁多，信息源的频率范围越来越宽，也就是说，我们的研究对象更加复杂；二是随着信息科学和技术发展，科学家和工程师获取信息的手段与方法越来越多样化。如在医院里医生获取思考疾病信息的手段不再是单靠过去的听诊器(即单传感器)，而是利用一系列电子和生物化学的医疗设备，如 CT、核磁共振、B 超等多种设备(即多传感器)。实际上，人们早就不知不觉地进入了多传感器信息融合的年代。因而人们面临着两个方面的挑战：一是如何构造多传感器系统，并更加有效地综合各种传感器提供的各类信息，以获得更准确而完整的信息，这就是信息空间的结构认识和构造问题；二是如何处理来自不明信号源、不确定的、非线性、非高斯、非平稳、低信噪比的信号，它们不仅是模拟或数字信号，而且包括用模糊语言表示的语言型模糊信息，并能对外部环境变化做出灵活的自适应反应，从而实现高性能智能信息处理与控制。这就是信息的获取、加工、处理、融合问题，这种新的挑战就是信息融合技术的研究对象和目标。

一门新技术、新学科的创立，不仅仅是理论研究的结果，更重要的是实际

工程的需求。在工业应用中常用一组传感器对同一个被测量目标在一个过程的不同位置进行测量。然而由于每个传感器位于过程的不同位置，它们将不同程度的受到噪声的干扰，为了从被噪声干扰的多传感器测量值中获得更准确的测量结果，需要进一步研究多传感器的融合理论。

## 1.2 数据融合的基本原理及定义

### 1.2.1 基本原理

人类的信息活动可以抽象为：获取数据、提取信息、上升为知识和决策控制等几个阶段。例如，人通过各种感觉器官(眼、耳、鼻、手等)来获取各种数据(如图像、声音、气味和触觉等)，然后根据先验知识、经验等对这些数据进行去伪存真、由表及里的处理过程以提取有用的信息，再将这些信息上升为新的知识，并基于这些知识做出反应式决策。与此同时，人还可以根据需要不断调整自己的感官，使得人的感官对于不同时空范围内发生的物理现象能采用不同的测量特征来度量、获取和提炼。因此，人的信息活动过程实际上是一种复杂的自适应反馈控制过程。

为了使系统能够在复杂环境中、在无人干预的条件下正常工作，就必须使系统具有类似于人的这种信息处理能力。要达到这一目的，首先要求系统的传感器能提供足够多和足够好的原始信息，其次是系统应采用有足够智能的信息处理方法。系统所使用的传感器类型、性能、数量以及传感器的布置和组织方法，对于不同目的和不同时空条件都应有一个合理要求，采用的信息处理技术

应该在不同层次实现简化、压缩、滤波、提取特征、映射、变换、学习和决策等功能，这也是多传感器融合技术所涉及的主要内容。

### 1.2.2 定义

信息融合这一词首先来源于美国，它的研究起源于军事C<sup>3</sup>I(Command, Control, Communication and Information)系统建设的需求，并于80年代发展成一项专门技术，它是人类模仿自身信息处理能力的结果<sup>[1]</sup>。数据融合最早用于军事，1973年美国研究机构就在国防部的资助下，开展了声纳信号解释系统的研究。从那以后，特别是自从海湾战争以来，致力于数据融合研究的人数和这一领域论著的数量显著增加，大大推动了数据融合技术的发展。目前，在C<sup>3</sup>I系统中都在采用多传感器融合技术，在工业控制、机器人、空中交通管制、海洋监视和管理等领域也朝着多传感器融合方向发展。多传感器融合技术成为军事、工业和高技术开发等多方面关心的问题。20多年来，以军事应用为目标的数据融合技术在工业、农业、航天、目标跟踪和惯性导航等领域得到了普遍关注和应用。然而，对数据融合还很难给出一个统一的、全面的定义。美国国防部JDL(Joint Directors of Laboratories)从军事应用的角度把数据融合定义为<sup>[2]</sup>：将来自多传感器和信息源的数据和信息加以联合(Association)、相关(Correlation)和组合(Combination)，以获得精确的位置估计(Position Estimation)和身份估计(Identity Estimation)，以及对战场情况和威胁及其重要程度进行适时的完整评价。美国国防部1998年公布的第二版《联合作战科学技术计划》则

称:数据/信息融合是一种由多个探测器各提供一组单独的关于目标和背景的数据,然后再把这些数据处理为融合的数据/信息的技术。融合的数据/信息向战区司令员们所展示的作战空间的情景,要比单独的几组数据简单相加所展示的情景要准确得多。

所谓数据融合,简单的说是指对来自多个传感器的数据进行多级别、多方面、多层次的处理,从而产生新的有意义的信息,而这种信息是任何单一传感器所无法获得的<sup>[2]</sup>。多传感器数据融合把系统中各传感器所提供的观测数据协调的组合起来,形成对周围环境实况的更可靠的判断。即使环境发生变化,系统的部分设备产生技术故障或损坏时也能保持这种判断的最好效果。

随着数据融合和计算机应用技术的发展,根据国内外的研究成果,多传感器数据融合比较确切的定义可概括为:充分利用不同时间与空间的多传感器数据资源,采用计算机技术对按时间序列获得的多传感器观测数据,在一定准则下进行分析、综合、支配和使用,获得对被测对象的一致性解释与描述进而实现相应的决策和估计,使系统获得比它的各组成部分更充分的信息。多传感器系统是数据融合的硬件基础,多源信息是数据融合的加工对象,协调优化和综合处理是数据融合的核心。

目前,数据融合是针对一个系统中使用多个和(或)多类的传感器这一特定问题展开的一种新的数据处理方法,因此数据融合又称作多传感器信息融合或信息融合。用同多种传感器对某一对象的特征进行测量的系统称为多源多传感器系统。用同一类传感器对某一对象的特征进行测量的系统称为同源多传感器系统,例如测量表征目标的各种参数,融合方法主要是参数估计,是一种通过估计减小和消除参数中的不确定性,从而达到提高参数精度的处理过程。本文



重点讨论的是同源多传感器系统。

### 1.2.3 多传感器数据融合系统的优点

多传感数据融合系统最终的目的是对被观测对象的状态给出精确的评估以便采取适当的应对措施。多传感器系统较之单传感系统在估计性能上有很大的优越性，其中包括：

#### (1) 提高了信息的可信度

利用多传感器能够更加准确地获得环境与目标的某一特征或一组相关特征，整个系统所获得的综合信息与任何单一传感器所获得的信息相比，具有更高的精度和可靠性。

#### (2) 增加了目标特征矢量的维数

各个传感器性能相互补充，收集到的信息中不相关的特征增加了，整个系统获得了任何单个传感器所不能获得的独立特征信息，可显著提高系统的性能，使多传感器系统不易受到自然现象的破坏或外界的干扰。

#### (3) 降低了获得信息的费用

与传统的单个传感器系统相比，在相同的时间内，多传感器系统能够获得更多的信息，从而降低了获得信息的费用，这在测量运动速度快的目标时尤为重要。

#### (4) 减少了信息获取的时间

由于多传感器系统的信息处理是并行的，从而大大缩短了系统信息处理的

总时间。

(5) 提高了系统的容错能力

由于多个传感器所采集的信息具有冗余性，当系统中有一个甚至几个传感器出现故障时，尽管某些信息减少了，但仍可由其他传感器获得有关信息，使系统继续运行，具有很好的容错能力。

(6) 提高了整个系统的性能

国外已从理论上证明了，通过多传感器信息的融合而获得的对环境或目标状态的最优估计，不会使整个系统的性能下降，即多传感器信息融合系统的性能不会低于单传感器系统的性能，并且证明了使用多传感器一般总能提高系统的性能。

### 1.3 数据融合算法

目前所研究的多传感信息融合，主要是指利用计算机进行多源信息处理，从而得到可综合利用信息的理论和方法，数据融合的关键问题是融合算法。

早在 20 世纪 80 年代，Hall 和 Llinas<sup>[3]</sup> 考察了 30 个信息融合系统，并归纳了所使用的 75 种融合算法。目前信息融合算法有上百种，可分为位置融合、身份融合、辅助支持算法等三大类，但在实际应用时这三种算法集成在一起。位置算法主要采用统计算法，而身份融合算法一般采用基于目标特征的无参或启发式算法，辅助支持算法主要包括基本的数值算法、数据校对、数据处理技术等<sup>[2,5,7]</sup>。通常随机类方法可应用于各级融合算法中，而人工智能方法一

般应用于较高层次上，采用何种算法主要取决于具体问题的实际需要。

贝叶斯方法是常用的辅助支持算法，该算法依据单个传感器提供的不完整、不精确、模糊的信息进行推理，以达到对目标身份识别和属性判决的目的。然而，该方法无法说明传感器组中具体的某一个传感器的测量不确定性<sup>[4]</sup>；同时由于该方法是基于统计的，所以统计数据量的大小决定了该算法的有效性。数据量越大就能得到对目标更为准确的描述。但是就需要大的存储器，而且计算量也会随之增加<sup>[5]</sup>。文献[6]采用神经网络的方法进行数据融合，但为了训练神经网络，往往需要很大的数据量。在实际的应用中，为了存储这些数据需要大容量的存储器，所以在实现上代价比较大。而且通过对一组特定数据集训练得到的神经网络，只适用于特定的应用环境。当应用环境改变时，必须重新训练神经网络，因此通用性很差。文献[7]应用模糊数学的方法去确定传感器测量值的可信度，并且将该方法成功地用于熔铁炉的温度测量。然而，与神经网络的方法一样，基于模糊数学的数据融合算法的关键在于模糊集的界定，所以当应用环境改变时，必须重新界定模糊集。文献[22]采用多电极的方法来克服非对称管流对电磁流量计测量精度的影响。其基本原理是多电极中每对电极都可以作为一个流量传感器，那么多电极可以组合成一个传感器组，对每一个传感器的测量值通过对其进行加权数据融合以达到提高测量精度的目的。提出了基于递归的估计方差的融合算法，进而对电磁流量计的流量进行递归估计的方法。由于该算法用滑动平均模型（MA）估计噪声方差，所以对于静态或缓慢时变过程是很有效的，即如果电磁流量计的流量较平稳，用该方法估计流量是简单而且有效的；但当流速发生突变或者流速较快时，用滑动平均模型估计的噪声方差在被测参数变化较快的情况下是有问题的，因此，对流速的估计

值也是有问题的。

位置融合算法主要应用于多传感器目标跟踪系统。目标跟踪系统是为了保持对目标当前状态的估计而对所接收到的测量信息进行处理软、硬件系统，目标跟踪中的比较重要的一类滤波器是卡尔曼滤波。卡尔曼滤波是一个对动态系统的状态序列进行线性最小方差误差估计的算法，通过以动态的状态方程和观测方程来描述系统。它可以以任意一点作为起点开始观测，采用递归滤波的方法计算。它具有计算量小、可实时计算的特点。对于高斯噪声的线性系统，卡尔曼滤波器很好的解决了这类估计问题。然而，很多动态系统都是非线性的，这就牵涉到非线性估计问题，非线性滤波理论<sup>[8]</sup>已成为滤波算法研究的热点，并已获得一定进展。一种方法是用扩展卡尔曼滤波(Extended Kalman Filter, EKF)方法进行滤波。这类方法需要对模型进行线性化处理。该类算法要求状态估计的概率密度函数满足高斯分布。但实际系统往往是非高斯非线性的(即系统状态/量测模型是非线性的，模型/量测噪声不服从高斯分布)。EKF需要对非线性模型作线性化处理，但EKF仅仅利用了非线性函数Taylor展开式的一阶偏导部分(忽略高阶项)，常常导致在状态的后验分布的估计上产生较大的误差，影响滤波算法的性能，从而影响整个跟踪系统的性能。[9]中讨论了测量方程非线性对EKF滤波精度的影响，并给出了一个简单的消除此影响的方法。该方法按先方位角后斜距的顺序依次处理雷达测量数据。对非线性程度不高情形，此方法能提高传统EKF的估计精度，但当非线性程度较高时，此方法的滤波性能也不能满足要求。

最近，在自适应滤波领域又出现了新算法——Unscented Kalman Filter (UKF)。该算法广泛的应用于非线性系统在线实时估计<sup>[10,11,12,13,14,15]</sup>。算法

计算量与EKF基本相当，而性能更优。

UKF算法是在1995年由剑桥大学Julier<sup>[10,11]</sup>等人提出的，比较完整的结果发表于2000年的IEEE Trans. on Automatic Control<sup>[12]</sup>。在此以后，该算法得到了广泛关注。Eric A. Wan为首的研究小组推广了该算法<sup>[13]</sup>，将算法应用于非线性系统的辨识<sup>[13]</sup>，神经网络参数训练和语音增强<sup>[14]</sup>。另外，MITRE公司的研究人员将UKF算法用于导弹发射阶段参数估计问题<sup>[16]</sup>取得了比EKF算法好的估计精度。

## 1.4 论文的主要工作及内容安排

本文的主要工作集中于多传感器数据融合算法的研究，提出了基于奇异值分解的数据融合算法；结合小波去噪及数据融合进行了传感器的数据重建，并将此算法用于实际的试验，进一步验证此算法的有效性；在对数据融合有了一定的理解的基础上，进一步研究了多传感器状态估计，运用UKF滤波结合多传感器数据融合的思想，提出了基于UKF的多传感器状态估计及融合。

第二章介绍一种基于奇异值分解的动态多传感器数据融合算法。第三章提出基于小波降噪和数据融合的多传感器数据重建算法。第四章讨论多传感器状态融合估计。最后给出本文结论。

## 第2章 基于奇异值分解的多传感器数据融合算法

### 2.1 引言

在工业应用中常用传感器组对同一个被测量目标在同一过程的不同位置进行测量,以获得对被测目标的更为准确的描述。多传感器数据融合技术其算法的关键在于确定各个传感器测量值的可信度,即确定每一个传感器的测量值的权值,从而可以从多传感器数据中获得对被测参数的更为精确地描述。

### 2.2 背景及问题的提出

多电极电磁流量计是适应非轴对称管流流量测量的需要而提出的。由于流速在管道截面上分布的非轴对称性,使得采用单对电极测量模式的传统电磁流量计会产生很大的测量误差<sup>[18]</sup>。多电极电磁流量计由于可以从多角度多位置测量感应电势(或电压)。因而可以用于非轴对称管流流量的精确测量<sup>[17]</sup>。

Shercliff<sup>[18]</sup>首先对单对电极的电磁流量计进行了较系统的分析,并提出了权重函数估计法。指出由于权重函数分布的不均匀导致传统单对电极电磁流量计对流型是敏感的。Yousif<sup>[19]</sup>等人从权重函数角度讨论了大电极电磁流量计对流型敏感性的改善作用及大电极的污物沉积效应对测量性能的影响。后来又出现了基于电容原理的非接触极板式电极电磁流量计<sup>[20]</sup>,在一定程度上平滑了点电极权重函数的影响,并克服了接触电极污物沉积的影响。

Engl<sup>[21]</sup>采用均匀磁场，通过对传感器管壁上感应电势积分获得了在任意流型下平均流速的数学表达式，可用于非轴对称管流平均流速的精确测量。Horner<sup>[17]</sup>等人在Engl公式的基础上，提出了以层析成像理论为基础的多电极电磁流量计测量平均流速的方法。试验结果表明，多电极电磁流量计可得到精确的平均流速估计。文献[22]采用旋转磁场及弦端电压差测量方法，并提出一种基于最小方差的流速估计算法。

### 2.2.1 理论基础

图2.1为多电极电磁流量计电极截面示意图。 $\Omega$ 和 $L$ 代表内部区域和边界。截面中的流速场 $\vec{v}(\vec{x})$ 沿 $z$ 流向读者。均匀磁场 $\vec{B}$ 指向 $y$ 负向。




图 2.1 多电极(16)电磁流量计示意图

为计算方便，截面半径 $r$ ，磁场强度 $B_0$ ，流速平均值 $\bar{v}$ ，均设置为1。根据欧姆定律，电磁流量计管道内电场的普通公式

$$\vec{E} = \rho \vec{j} - \vec{v} \times \vec{B} \quad (2.1)$$

其中： $\vec{E}$  是电场强度； $\rho$  是液体的电阻率； $\vec{j}$  是电流密度； $\vec{v}$  是液体流动速度； $\vec{B}$  是磁感应强度。

由于激磁电流的角频率  $\omega$  很低，位移电流完全可以忽略，可以只考虑传导电流。这时，电流密度的散度等于零，即：

$$\nabla \cdot \vec{j} = 0 \quad (2.2)$$

把(2.1)式代入(2.2)式，并假设液体的电阻率是均匀的，而且是各向同性的，即  $\nabla \rho = 0$ ，设电场置的电势为  $U$ ，则  $\vec{E} = -\nabla U$ ，可得到电磁流量计的微分方程式：

$$\nabla^2 U = \nabla \cdot (\vec{v} \times \vec{B}) \quad (2.3)$$

由于  $\vec{B}$  是均强磁场，并假设流速只有  $z$  轴方向上的分量，则上式简化为：

$$\nabla^2 U = B_0 \frac{\partial}{\partial x} (v_z(x, y)) \quad (2.4)$$

采用0形非均匀网格剖分有限差分法<sup>[23]</sup>，可解得上述微分方程在特定边界条件下的数值解，即得到电极截面上各点电势。而各电极对上的电势差即为多电极电磁流量计的测量值。

### 2.2.2 平均流速估计

文献[23]从法拉第电磁感应定律出发，推导出适用于多电极对电磁流量计平均流速测量的弦端电压差测量方法，并给出两种弦端电压差测量值加权方



法。计算结果表明弦端电压差测量方法对多对电极电磁流量计是有效的<sup>[22, 23]</sup>，并且具有物理意义清晰的特点。其中文献[22]证明了弦端电压差测量并加权求和的方法与Engl方法的一致性。平均流速的计算表达式为：

$$\hat{v}_z = \frac{2}{N} \sum_{i=1}^{\frac{N}{2}-1} \frac{1}{B_0} U_{CD}(\varphi_i) \cdot \cos \varphi_i \quad (2.5)$$

其中

$$U_{CD}(\varphi_i) = U_D - U_C = U(\varphi_i) - U(\pi - \varphi_i) \quad (2.6)$$

(2.6)式表示某电极对上电压差。 $\varphi_i$ 表示此电极对在电极坐标下的角位置(如图2.1所示)。 $N$ 表示电极数。

### 2.2.3 基本原理

文献[22]采用多电极的方法来克服非对称管流对电磁流量计测量精度的影响，如图2.1所示。其基本原理是多电极中每对电极都可以作为一个流量传感器，那么多电极可以组合成一个传感器组，对每一个传感器的测量值，通过对其进行加权数据融合以达到提高测量精度的目的。提出了基于递归的估计方差的融合算法，进而对电磁流量计的流量进行递归估计的方法。

由于该算法用滑动平均模型(MA)估计噪声方差，所以对于静态或缓慢时变过程是很有效的，即如果电磁流量计的流量较平稳，用该方法估计流量是简单而且有效的；但当流速发生突变或者流速较快时，用滑动平均模型估计的噪声方差在被测参数变化较快的情况下是有问题的，因此，对流速的估计值也

是有问题的。

## 2.3 基于 SVD 的多传感器数据融合算法

为了更为准确地获得传感器的信息，本章提出了基于 SVD 的多传感器数据融合算法。将传感器组中由每一个传感器获得的一组测量结果，通过预处理后作为一个输入矩阵的列向量。那么该传感器组的全部测量结果就构成了一个输入矩阵。对输入矩阵作 SVD 分解，得到大小不同奇异值，这些不同的奇异值说明了各个传感器输出信号能量分布的不同。引起奇异值差别的原因在于各个传感器受到的噪声的干扰不同。这就意味着可以在 SVD 的基础上由奇异值估计出每个传感器测量数据的可信度。对于可信度高的传感器测量数据赋予大的权值，而对于可信度较低的传感器测量数据赋予小的权值，从而估计出被测参数。

### 2.3.1 数据融合算法

为了使建议方法具有一般性，假设有 $N$ 个传感器对同一被测参数 $S$ 在一个工业过程不同位置进行测量，经由每个传感器得到的测量值记为 $Y_j(j=1,2,\dots,N)$ ，由于测量过程中，存在内部和外部噪声的影响，测量值可以表示为：

$$Y_j(n) = S(n) + e_j(n) \quad (j=1, 2, \dots, N) \quad (2.7)$$

$S(n)$ 为被测参数,  $e_j(n) (j=1, 2, \dots, N)$ 为第  $j$  个传感器在  $n$  时刻的加性噪声。 $Y_j(n) (j=1, 2, \dots, N)$ 为第  $j$  个传感器在  $n$  时刻的观察值。由于每个传感器受到噪声干扰的程度不同, 所以  $Y_j(n) (j=1, 2, \dots, N)$  偏离真实的被测参数的程度是不同的。对每一个传感器根据一定的原则赋予一个权值  $W_j$ , 从这  $N$  个传感器得到的估计值  $\hat{Y}$ 。

$$\hat{Y} = \sum_{j=1}^N W_j Y_j \quad (2.8)$$

$W_j$  为  $Y_j (j=1, 2, \dots, N)$  的权值, 同时  $W_j$  满足  $\sum_{j=1}^N W_j = 1$ 。

当  $W_j$  对于每一个  $j$  是常数, 那么  $\hat{Y}$  就是  $Y_j (j=1, 2, \dots, N)$  的均值。即  $W_j = 1/N$ , 那么得到的估计值也就是一个平均估计。然而, 这个结果并不是最优的。

由 (2.8) 式定义的估计的方差可表示为:

$$\sigma^2 = E[\sum_{j=1}^N W_j^2 (Y - Y_j)^2] = \sum_{j=1}^N W_j^2 \sigma_j^2 \quad (2.9)$$

因为 (2.9) 式右边是  $W_j$  的二次多项式, 因而存在最小值  $\sigma_{\min}^2$ , 当

$$W_j = \frac{1}{\sigma_j} \cdot \frac{1}{\sum_{i=1}^N \frac{1}{\sigma_i}}, \quad j = 1, \dots, N \quad (2.10)$$

时, (2.9) 式取最小值:

$$\sigma_{\min}^2 = \frac{1}{\sum_{i=1}^N \frac{1}{\sigma_i}} \quad (2.11)$$

我们知道当各传感器受到噪声干扰的程度不同时，各传感器测量值的方差将不一致，即各传感器测量值的可信度是不同的。式(2.11)说明若将较大的权值赋予可信度高的传感器，将较小的权值赋予可信度小的传感器，这样就可以使融合估计的测量值具有更小的测量方差，即多传感器加权融合的方法可以得到更为精确的测量结果。因此，必须对传感器的可信度进行分析评价，由可信度来确定每一个传感器的权值。文献[22]中在方差基本定义的基础上，采用MA模型用递归的方法估计方差，再根据最小均方误差（Minimum Mean Square Error, MMSE）理论估计权值，从而估计出流量。本文试图通过奇异值分解的方法来讨论更为准确描述传感器可信度的途径。

### 2.3.2 基于奇异值分解的权值估计

将传感器组中由每一个传感器获得的一组测量结果，作为一个输入矩阵的列向量。那么该传感器组的全部测量结果就构成了一个输入矩阵：

$$\mathbf{Y} = [\mathbf{Y}_1 \quad \mathbf{Y}_2 \cdots \mathbf{Y}_N] = \begin{bmatrix} Y_1(1) & Y_2(1) \cdots Y_N(1) \\ Y_1(2) & Y_2(2) \cdots Y_N(2) \\ \vdots & \vdots \cdots \vdots \\ Y_1(n) & Y_2(n) \cdots Y_N(n) \end{bmatrix} \quad (2.12)$$

由矩阵范数理论知，由传感器组测量结果构成矩阵的SVD分解的得到的奇异值的大小，说明了不同传感器信号的能量分布。由于 $N$ 个传感器的被测参

数是相同的，不同的只是受噪声干扰的程度。因此奇异值的大小仅仅说明传感器受噪声干扰的程度的不同。文献[24]给出了奇异值分解的定义，设  $\mathbf{Y}$  是  $m \times n$  的矩阵，必存在正交阵  $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_m] \in R^{m \times m}$  和  $\mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_n] \in R^{n \times n}$ ，使得：

$$\begin{aligned} \mathbf{U}^T \mathbf{Y} \mathbf{V} &= \text{diag}(\sigma_1, \dots, \sigma_p) \in R^{m \times n}, p = \min\{m, n\} \\ \mathbf{Y} &= \mathbf{V} \Sigma \mathbf{U}^T, \Sigma = \text{diag}(\sigma_1, \dots, \sigma_p) \in R^{m \times n}, p = \text{rank}(\mathbf{Y}) \end{aligned} \quad (2.13)$$

计算奇异值最为常用的方法是 Golub-Reinsh 算法<sup>[24]</sup>，Matlab 中就使用该算法实现矩阵的奇异值分解，但是所有奇异值按由大到小的顺序重排，因此，也就无法确定每一个奇异值与输入矩阵的列向量的对应关系<sup>[25]</sup>。

文献[26]给出了如何确定每个奇异值  $\sigma_i$  与在输入矩阵  $\mathbf{Y}$  中的位置。该算法，对输入矩阵做一系列的单边的 Jacobi 变换，

$$\mathbf{B} = \mathbf{U}^T \mathbf{Y}, \mathbf{Y} \in R^{m \times n}, m > n \quad (2.14)$$

$\mathbf{B}$  为行向量正交矩阵，而  $\mathbf{U}$  的行向量和列向量均正交。再将得到的  $\mathbf{B}$  矩阵做 QR 分解，得到：

$$\mathbf{B} = (\mathbf{B}^T)^T = (\mathbf{Q}_B \mathbf{R}_B)^T = \mathbf{R}_B^T \mathbf{Q}_B^T \quad (2.15)$$

令  $\Sigma = \mathbf{R}_B^T, \mathbf{V}^T = \mathbf{Q}_B^T$ ，则实现了输入矩阵  $\mathbf{Y}$  奇异值分解

$$\mathbf{Y} = \mathbf{U} \Sigma \mathbf{V}^T \quad (2.16)$$

用该算法，就可以得到输入矩阵  $\mathbf{Y}$  的未经重排的奇异值，即不同的奇异值按顺序对应输入矩阵的列向量。

为了确定每一个奇异值与输入矩阵 (2.12) 的列向量的对应关系，本文采

用了单边的 Jacobi 算法<sup>[24]</sup>，从而得到未经重新排序的奇异值，也就确定了每个奇异值  $\sigma_j$  与输入矩阵  $\mathbf{Y}$  的列向量  $Y_j (j=1,2,\dots,N)$  的对应关系，同时也就得到了对应的传感器的信息。

然而，由于在实际应用中，传感器制造上的差别，或传感器位于一个过程的位置不同会导致传感器的输出信号与原信号无论是直流分量还是谐波分量都会有所不同。在此情况下，由于各个传感器的直流成分不同，所以各个传感器的均值也是不同的。因此，对输入矩阵 (2.10) 作 SVD 分解得到的奇异值的大小，也就无法准确地说明信号受噪声干扰的程度。为了得到噪声的能量分布，需要对每个传感器的测量值做预处理。从各个传感器的测量值中将平均值减去，就得到零均值的测量值。

$$\mathbf{Y}'_j = \mathbf{Y}_j - \text{mean}(\mathbf{Y}_j) \quad (j = 1, 2, \dots, N) \quad (2.17)$$

以各个传感器经过预处理后的测量值作为输入矩阵的列向量，得到新的输入矩阵

$$\mathbf{Y}' = [\mathbf{Y}'_1 \mathbf{Y}'_2 \dots \mathbf{Y}'_N] = \begin{bmatrix} Y'_1(1) & Y'_2(1) \dots Y'_N(1) \\ Y'_1(2) & Y'_2(2) \dots Y'_N(2) \\ \vdots & \vdots \dots \vdots \\ Y'_1(n) & Y'_2(n) \dots Y'_N(n) \end{bmatrix} \quad (2.18)$$

对 (2.18) 作 SVD 分解得到  $N$  个奇异值，这些大小不同的奇异值说明了信号的能量分布，即说明了噪声的能量分布。

设各传感器对应的奇异值为  $\sigma_j (j=1,\dots,N)$ ，而每一个奇异值反映了每一个传感器信号受噪声影响的程度，也就是反映了方差的大小。由 (2.10) 式即

可估计出各个传感器的权值。从而由 (2.8) 可以得到零均值的估计信号。为了得到信号的估计值需要估计平均值。(2.19) 中的  $\text{mean}$  为将  $N$  个传感器的均值做平均, 作为估计值的均值, 即可得到估计值,

$$\hat{Y} = \sum_{j=1}^N W_j Y_j' + \text{mean} \quad (2.19)$$

### 2.3.3 算法实现

该算法的步骤如下:

- (1) 令估计长度  $I$ ;
- (2) 预处理输入矩阵 (2.17);
- (3) 根据单边的Jacobi算法计算  $I \times N (I \geq N)$  阶预处理后的输入矩阵的奇异值, 得到  $N$  个奇异值  $\sigma_j (j=1, \dots, N)$ ;
- (4) 由 (2.10) 式计算  $W_j$ ;
- (5) 由 (2.8) 式计算  $\hat{Y}$ ;
- (6) 由 (2.19) 式计算估计值  $\hat{Y}$ ;

该算法的关键在于由Jacobi算法计算奇异值。一旦选定了估计长度, 由  $I \times N (I \geq N)$  个数据计算奇异值, 估计  $N$  个权值。估计长度  $I$  可以根据需要选择。

## 2.4 仿真结果及讨论

为了检验概算法的有效性,进行了下述仿真研究。设被测参数 $Y$ 是具有一定频率及幅值的信号。令

$$Y(t) = a_i + \sum_i b_i \sin(2\pi f_i t) + e(t) \quad (2.20)$$

式中 $a_i$ 为被测参数的直流成分, $b_i$ 、 $f_i$ 分别为信号的幅值和频率。 $e(t)$ 为零均值的平稳噪声。

本文采用4个传感器对 $Y$ 进行测量,仿真中采用零均值的平稳噪声叠加在传感器的测量列上。仿真中取数据长度为 $I=100$ 。对 $100 \times 4$ 的矩阵作奇异值分解,得到对应于各个传感器的4个奇异值。

为了说明该算法的性能,本文以被测量受到不同程度的噪声和具有不同谐波信号的工频干扰为例,将该算法与基于MMSE的算法作比较,给出在两种算法下得到估计值与真实值的方差比较,并给出两种算法在不同SNR条件下的方差比较,仿真中方差定义为:

$$\sigma^2 = \frac{1}{N} \sum (Y - S)^2 \quad (2.21)$$

$S$ 为被测量的真实值,当 $Y$ 为各传感器的测量值,得到的是测量值的方差;当 $Y$ 为融合结果时,得到的是估计值的方差。本文的仿真,给出在噪声影响下由两种算法得到的估计值的方差比较,以说明该算法的有效性。


### (一) 直流信号

假设被测参数为:




$$S(t) = 5$$

如图2.2(a)为被测参数分别受到方差0.2，0.1，0.8和0.5的高斯噪声干扰的情况下在两种算法下的融合结果的仿真结果；如图2.2(b)为被测参数分别受到方差5，7，12和7.5的高斯噪声干扰的情况下在两种算法下的融合结果的仿真结果；表2.1所示的仿真结果表明，当原信号为一直流信号时，基于奇异值分解的多传感器数据融合算法得到估计值的方差不仅低于每一个传感器的方差，而且低于基于MMSE算法得到的估计值的方差。



(a)



(b)

图 2.2 直流信号在两种算法下的方差比较

Variance of Sensor1	Variance of Sensor2	Variance of Sensor3	Variance of Sensor4	Variance of MMSE	Variance of SVD
1.2097	2.5055	16.2380	12.2846	6.2622	0.2469
1.9873	3.0978	16.9780	12.8840	6.4197	0.4446
4.0100	3.4598	18.2434	12.5475	6.5462	0.5328
4.1262	7.0071	22.9407	17.6824	7.2407	1.5093
3.8227	7.2670	36.3546	17.6923	7.3011	1.9205

表 2.1 在不同误差下各传感器及两种算法下得到估计值的方差比较


为了检验该算法的动态应用效果，任意给定各次谐波的频率和初相位，仿真结果如下。

## (二) 具有1次谐波的直流信号


假设被测参数为：

$$S(t) = 5 + 5\sin(2\pi(0.2)t + 0.1)$$

如图2.3(a)为被测参数分别受到方差0.8，0.5，2.5和7.5的高斯噪声干扰的情况下在两种算法下的融合结果的仿真结果；如图2.3(b)为被测参数分别受到方差3，2，10和8.5的高斯噪声干扰的情况下在两种算法下的融合结果的仿真结果。



(a)



(b)

图 2.3 具有1次谐波的直流信号在两种算法下的方差比较

Variance of Sensor1	Variance of Sensor2	Variance of Sensor3	Variance of Sensor4	Variance of MMSE	Variance of SVD
6.8889	6.1142	23.4215	34.1228	9.6712	0.7833
7.5798	7.3562	24.0963	34.7523	10.1160	1.4052
8.5676	8.5145	25.8361	35.8039	10.2771	1.5309
13.8715	10.8066	26.0593	39.1480	10.7091	2.3245
15.3926	11.2734	41.9409	39.6445	11.8559	3.0974


表 2.2 在不同 SNR 下各传感器及两种算法下得到估计值的方差比较

(三) 具有3次谐波的直流信号


假设被测参数为：

$$Y(t) = 5 + 0.3\sin[2\pi t(0.2) + 0.1] \\ + 3\sin[2\pi t(0.24) + 1.12] + \sin[4\pi t(0.2) + 0.2]$$

如图2.4(a)为被测参数分别受到方差0.5, 0.8, 2和7的高斯噪声干扰的情况下在两种算法下的融合结果的仿真结果; 如图2.4(b)为被测参数分别受到方差6.5, 4.5, 10和8.5的高斯噪声干扰的情况下在两种算法下的融合结果的仿真结果。



(a)



(b)

图 2.4具有 3 次谐波的直流信号在两种算法下的方差比较

Variance of Sensor1	Variance of Sensor2	Variance of Sensor3	Variance of Sensor4	Variance of MMSE	Variance of SVD
11.4236	14.1990	25.4932	34.1584	10.7740	2.2991
11.8149	14.4724	25.9435	34.6054	10.9188	2.3895
12.9007	15.8544	26.1077	34.3790	10.9249	2.5039
19.2602	20.1129	29.4113	38.7330	11.5706	3.3427
32.6817	19.5963	30.9172	41.7285	13.0318	4.4928

表 2.3 在不同 SNR 下各传感器及两种算法下得到估计值的方差比较

如表2.1、2.2、2.3所示的仿真结果表明，当被测量为具有谐波的直流信号时，基于奇异值分解的多传感器数据融合算法估计值的方差低于MMSE算法得

到的估计值的方差。仿真研究表明该算法是有效的。本文也对具有5次谐波的直流信号作了仿真，得到的结果与上述仿真实验的结果一致，算法也同样有效。

## 2.5 本章小结

本章提出了基于奇异值分解的多传感器数据融合算法，由输入矩阵的 SVD 分解得到的奇异值可以较准确地描述信号的能量特征，从而更为准确地说明了信号受噪声干扰的程度，更好地说明了传感器组中各个传感器的特征。由奇异值估计每个传感器的权值，从而可以估计出在最小方差意义的被测参数。仿真结果表明，由该算法得到的最优估计的方差不仅低于传感器组中每一个传感器信号的方差，而且低于由基于递归 MMSE 的多传感器数据融合算法得到的估计结果的方差。同时数据量的大小可以根据需要调整，因此该算法具有很大的通用性和灵活性。

## 第3章 多传感器数据重建

### 3.1 引言

从第二章知道在工业应用中常用传感器组对同一个被测参数目标在同一工业过程的不同位置进行测量,可以获得对被测目标更准确的描述。同时,在许多工业过程中,人们需要控制被测参数的分布,例如:文献[27]讨论的通过对一个熔化炉的炉子的进出口及炉内温度的分布进行测量,以控制其温度的分布,从而达到获得更高质量和性能产品的目的。然而,由于传感器阵列或传感器组中的每一个传感器可能不同程度的受到噪声的干扰,所以如果直接用这些传感器数据估计被测参数,得到的结果并不一定是最优的。为了获得对被测参数的更优的估计,需要从被噪声不同干扰的各个传感器测量值中重建传感器的数据。从而得到被测参数在一个工业过程中的分布。

为了从受到不同噪声干扰的各个传感器测量值中获得更准确的各个传感器数据,在本章里提出了一种基于小波去噪和多传感器数据融合的传感器数据重建算法。这方法是首先将每个传感器的测量值用小波阈值的方法去噪,减小噪声对传感器测量值的影响。为了得到更好的重建传感器信号,先将各个传感器测量值进行归一化,再将归一化后的各个传感器测量值做基于 MMSE 的数据融合。最后,用融合的结果对每一个传感器数据进行相应的逆处理,即可得到各个传感器的重建测量值。仿真和实验的结果都表明该算法的有效性。



### 3.2 基于小波去噪及多传感器数据融合的传感器数据重建算法

为了使建议方法具有一般性, 假设有 $N$ 个传感器对同一被测参数 $S$ 在一个工业过程不同位置进行测量, 经由每个传感器得到的测量值记为 $X_j(j=1,2,\dots,N)$ , 由于测量过程中, 存在内部和外部噪声的影响, 测量值可以表示为:

$$X_j(n) = S(n) + e_j(n) \quad (j=1,2,\dots,N) \quad (3.1)$$

$S(n)$ 为被测参数,  $e_j(n)(j=1,2,\dots,N)$ 为第 $j$ 个传感器在 $n$ 时刻的加性噪声。 $X_j(n)(j=1,2,\dots,N)$ 为第 $j$ 个传感器在 $n$ 时刻的观察值。由于每个传感器受到噪声干扰的程度不同, 所以 $X_j(j=1,2,\dots,N)$ 偏离真实的被测参数的程度是不同的。

#### 3.2.1 小波去噪

信号的小波去噪方法主要通过设置阈值实现。将信号进行离散小波变换, 得到该信号的小波系数, 然后剔除被认为与噪声有关小波的系数。通常的方法是设置阈值, 将小于阈值的小波系数去掉。最后, 然后通过小波变换的逆变换来得到信号。

小波阈值设置有两种方法<sup>[28]</sup>:

- (1) “硬” 阈值。此时所有小波系数小于设定阈值 $\theta$ 设为零,

$$\omega_{new} = \omega I(|\omega| > \theta);$$

- (2) “软” 阈值, 其中 $\omega_{new} = \text{sgn}(\omega)(|\omega| - \theta)I(|\omega| > \theta)$ 。

对于某给定的信号, 选取阈值 $\theta$ 的方法很多。其中较好的有 VISU 方法

<sup>[64]</sup>:  $\theta = \sigma \sqrt{2 \ln n}$ , 其中,  $n$  是样本数目,  $\sigma$  是噪声的标准方差 (假定已知或从数据中估计出)。另一个常见的提示是基于 Stein 无偏风险估计值最小化 (SURE, Stein Unbiased Risk Estimate) <sup>[29]</sup>:

$$\begin{aligned} SURE(t) &= n - 2 \sum_i I(t - |\omega_i|) + \sum_i \min(\omega_i^2, t^2) \\ \theta &= \arg \min SURE(t) \end{aligned} \quad (3.2)$$

表达式 (3.2) 给出作为一个阈值  $t > 0$  和信号小波系数  $\omega_i$  的函数, 同时也计算出最小化 SURE 的最优  $t$ 。方法 SURE 阈值的选取依赖于信号小波分解的层次, 而 VISU 方法阈值是不变的。本文采用 SURE 阈值的方法对各个传感器测量值作小波去噪, 得到去噪后的传感器数据  $Y_j(j=1, 2, \dots, N)$ 。

### 3.2.2 数据融合及数据重建算法

首先对每一个传感器获得的一组测量值用这组数据中的最大测量值归一:

$$Y'_j(n) = Y_j(n) / \text{Max}(Y_j(n)) \quad j=1, \dots, N; n=1, \dots, I \quad (3.3)$$

$\text{Max}(Y_j(n))$  是在估计长度  $I$  内第  $j$  个传感器的最大测量值。 $Y'_j(n)$  为第  $j$  个传感器在  $n$  时刻归一化后的测量值。

文献[22] 对每一传感器测量值在方差基本定义的基础上, 提出递归的估计方差的算法。根据第二章所讨论的权值的估计公式 (2.10), 将估计的权值赋予各个传感器, 估计出的结果将得到在 MMSE 意义下的最优估计结果  $\hat{Y}$ 。

然后再对  $\hat{Y}$  反归一化, 即可得到各个传感器的重建数据。

$$\hat{Y}_j(n) = \hat{Y}(n) \times \text{Max}(Y_j(n)) \quad j=1, \dots, N; n=1, \dots, I \quad (3.4)$$

### 3.3 算法及步骤

该算法的步骤如下：

- (1) 令估计长度 $I$ ;
- (2) 对各个传感器测量值作小波阈值去噪处理;
- (3) 采用MA模型用递归的方法估计方差<sup>[22]</sup>;
- (4) 由(2.10)式计算 $W_j$ ;
- (5) 由计算 $\hat{Y} = \sum_{j=1}^N W_j Y_j$ ;
- (6) 由(3.4)式计算各个传感器的重建数据;

### 3.4 仿真结果及讨论

为了检验该算法的有效性，进行了下述仿真研究。令 $Y(t) = a_i + \sum_i b_i \sin(2\pi f_i t) + e(t)$ ，式中 $a_i$ 为被测参数的直流成分， $b_i$ 、 $f_i$ 分别为工频干扰的幅值和频率。 $e(t)$ 为零均值的平稳噪声，信噪比（SNR）定义为：

$$SNR = 10 \log_{10} \left( \frac{S_q}{\sigma_e^2} \right) \quad (3.5)$$

$S_q$ 为信号的功率， $\sigma_e^2$ 为噪声的方差。

本文采用4个传感器对 $Y$ 进行测量，仿真中采用零均值的平稳噪声叠加在传感器的测量列上。仿真中取数据长度为 $I=100$ 。

为了说明该算法的性能，本文以被测参数受到不同程度的噪声为例，给出该算法在不同信噪比下得到估计值与真实值的方差比较，仿真中方差定义为：

$\sigma^2 = \frac{1}{N} \sum (Y - S)^2$ 。S为被测参数，当Y为各传感器的测量值，得到测量值的方差；当Y为各传感器的重建值，得到重建数据的方差。本文的仿真，给出在不同信噪比下由该算法得到的估计值的方差比较，以说明该算法的有效性。

(一) 设四个传感器的测量值为：

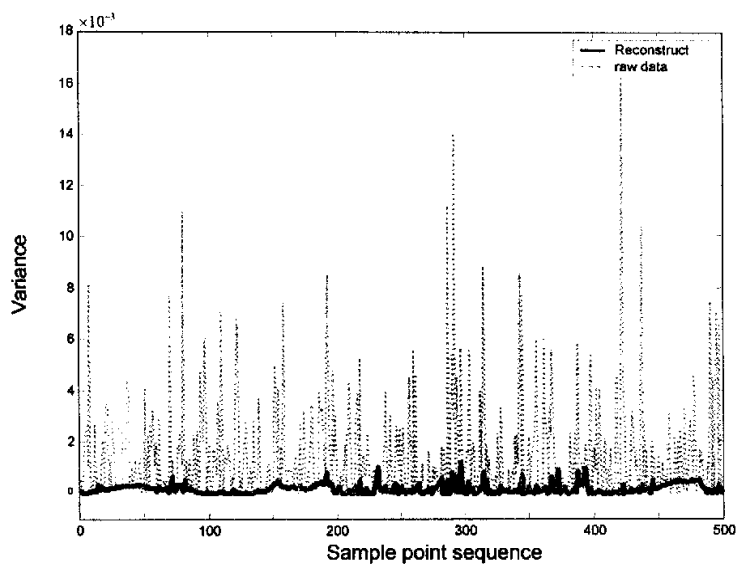
$$Y_1(t) = 4 + e_1(t)$$

$$Y_2(t) = 3 + e_2(t)$$


$$Y_3(t) = 2 + e_3(t)$$

$$Y_4(t) = 5 + e_4(t)$$

如图3.1所示，以四个传感器中的一个传感器为例，图a、b分别给出了在信噪比为12.2185dB和信噪比为0.1703dB，传感器测量值与重建数据的方差比较。实线为基于本文提出的算法得到的传感器重建数据的方差，虚线为传感器测量值的方差。表3.1列出了该算法在不同信噪比下的三次仿真结果，仿真结果表明，当原信号为一直流信号时，由该算法得到的各个传感器的重建数据的方差低于测量值的方差，当SNR较小时，重建数据的方差远远低于传感器测量值的方差，说明该算法具有较强的稳定性。



(a) SNR=12.2185dB



(b) SNR=0.1703dB

图 3.1 在不同 SNR 下测量值的方差与重建数据的方差

	SNR	测量值的方差	重建数据的方差
传感器1	19.3694	0.2940	0.0615
	9.9415	3.0345	0.4148
	-0.5163	32.3184	0.9372
传感器2	19.4007	0.3057	0.1489
	8.6705	3.0352	-2.6520
	29.0827	0.2489	1.8236
传感器3	23.8906	0.0965	0.0525
	8.8937	3.9316	1.0313
	4.49062	4.1697	1.2007
传感器4	21.2639	0.2229	0.0340
	11.0806	1.8942	0.1316
	2.00692	9.5091	1.7282

表 3.1 在不同 SNR 下测量值的方差与重建数据的方差比较

(二) 设四个传感器的测量值分别为：


$$Y_1(t) = 4 + 0.3 \sin[2\pi t(0.2) + 0.1] + 3 \sin[2\pi t(0.24)] + 1.12] \\ + \sin[4\pi t(0.2) + 0.2] + e_1(t)$$

$$Y_2(t) = 3 + 0.2 \sin[2\pi t(0.3) + 0.5] + \sin[2\pi t(0.3)] + 1.14] \\ + 3 \sin[4\pi t(0.2) + 0.2] + e_2(t)$$


$$Y_3(t) = 2 + 0.15 \sin[2\pi t(0.1) + 0.1] + 2 \sin[2\pi t(0.24)] + 1.13] \\ + \sin[4\pi t(0.3) + 0.3] + e_3(t)$$

$$Y_4(t) = 1 + 0.6 \sin[2\pi t(0.2) + 0.4] + 3 \sin[2\pi t(0.25)] + 1.15] \\ + \sin[4\pi t(0.4) + 0.1] + e_4(t)$$

如图3.2及表3.2所示的仿真结果表明，重建数据的方差低于传感器测量值的方差。尤其是在大噪声背景下由该算法得到的重建数据的方差大大低于传感器测量值的方差，说明该算法具备较强的可靠性。仿真研究表明该算法是有效的。本文也对具有1次和5次谐波的直流信号作了仿真，得到的结果与上述仿真实验的结果一致，算法也同样有效。



(a) SNR=12.2185dB



(b)在SNR=0.1703dB

图 3.2 在不同SNR下测量值的方差与重建数据的方差

	SNR	测量值的方差	重建数据的方差
传感器1	19.1946	5.2558	0.5623
	7.9452	9.0918	1.7634
	0.9555	26.5643	2.0956
传感器2	15.0766	13.6998	5.8559
	7.2951	16.2375	8.4060
	-0.23822	7.3378	5.4193
传感器3	17.2506	33.9599	0.8823
	3.2712	39.6865	1.7402
	2.9613	54.4182	2.8967
传感器4	14.3524	1.1543	0.5521
	5.6017	6.5453	1.3226
	-0.5961	24.8178	2.1088

表 3.2 在不同 SNR 下测量值的方差与重建数据的方差比较

### 3.5 实验平台结果

为了对本文提到的算法的有效性进行分析评估, 利用来自一个流量的实验平台中4个应变压力传感器的实测数据对提出的算法进行验证, 这个流量的实验平台如图3.3。4个应变压力传感器 (strain gauge sensor) 的安装位置如图3中的传感器1至4。由于孔板 (orifice plate) 的作用, 使得在孔板前后的压力不同。由于被测流体中杂质的影响, 传输到差分压力流量计的管道可能堵塞<sup>[65]</sup>。实验中用两个针孔阀用于模拟传输管的堵塞情况, 从而可以改变sensor2和3的测量到流体的压力, 将4个应变压力传感器 (strain gauge sensor) 获得的测量值经ADC采集卡送到计算机处理。采用本文提出的算法对4个应变压力传感器的测量值进行重建, 其结果如表3所示, 如当各个传感器测量值的方差分别为1.4958、0.6178、1.7033和0.7331时, 则基于该算法得到的各个传感器重建数据的方差为0.0087、0.0074、0.0112 和0.0085, 说明该算法是有效的。



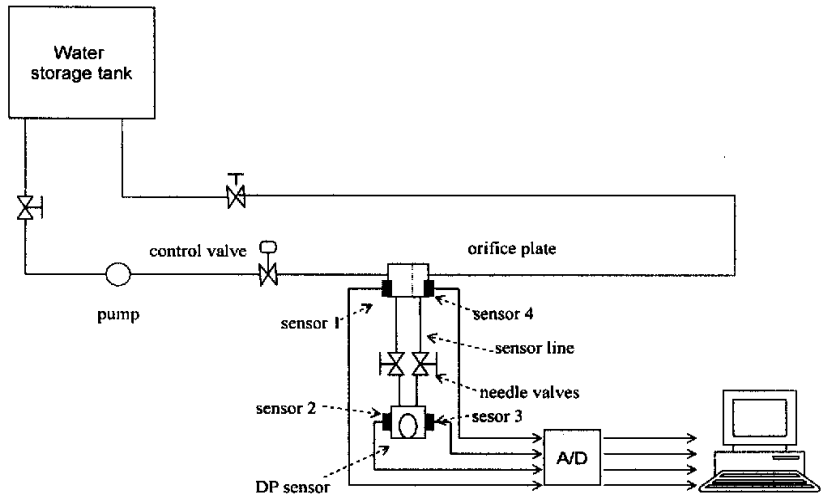


图 3.3 实验平台

	测量值的方差	重建数据的方差
传感器1	0.0980	0.0131
	0.0995	0.0155
	1.4958	0.0087
传感器2	0.1594	0.0363
	0.1522	0.0227
	0.6178	0.0074
传感器3	0.0920	0.0195
	0.0858	0.0112
	1.7033	0.0112
传感器4	0.2140	0.0504
	0.2023	0.0354
	0.7331	0.0085

表 3.3 测量值的方差与重建数据的方差比较

### 3.6 本章小结

本章提出了一种基于小波阈值去噪及多传感器数据融合的传感器数据重建算法。首先对各个传感器的测量值做小波阈值去噪，减小了噪声的影响。再利用多传感器系统的信息的冗余性及较强的容错能力，对被测参数进行估计。从而重建各个传感器的数据。该算法可以对一定长度的一组数据进行数据重建。仿真结果表明该算法是有效的。尤其是在大噪声背景下由该算法得到的重建数据的方差大大低于传感器测量值的方差，说明该算法具有较强的鲁棒性。应变压力传感器的实测数据的重建结果也表明了该算法的有效性。

## 第4章 非线性系统中多传感器状态融合估计

### 4.1 引言

动态系统的状态估计融合是多传感器数据融合的一个重要研究部分。文献[30]提出了在过程噪声为零的情况下确定性系统下的最优估计公式。然而,在实际应用中,过程噪声往往是不可忽略的。在这样的情况下,由于具有相同的过程噪声,来自不同传感器的测量值并不是相互独立的,文献[31]提出的融合公式也只是对跟踪目标的一个近似估计。在考虑测量值之间的相关性的情况下,文献[32]通过计算并分析了自不同传感器的测量值的协方差,在此研究基础上,文献[33]得到了融合估计。但是,文献[33]中贝叶斯估计的假设条件在实际应用中往往是无法满足的。因此,又有一些多传感器状态融合的方法相继提出。最为重要的就是卡尔曼滤波方法<sup>[34]</sup>,但是该方法只适用于线性系统。在线性化测量模型的基础上,进一步提出了适用于非线性系统的扩展卡尔曼滤波(EKF)方法<sup>[35]</sup>。EKF不能说是卡尔曼滤波的完全推广,只是一个用线性去近似非线性粗糙方法,EKF只是简单地将所有非线性模型线性化,然后再利用线性卡尔曼滤波方法,EKF给出的是最佳估计的一阶近似。

### 4.2 状态估计融合算法

### 4.3 非线性系统的状态估计

卡尔曼滤波问题都是假设物理系统的数学模型是线性的。但是，工程实践中所遇到的物理系统模型往往是非线性的，即系统方程是非线性的，或系统方程和量测方程均是非线性的。

#### 4.3.1 非线性离散系统模型

本节研究的随机离散非线性系统数学模型为

$$\begin{aligned} \mathbf{X}(k+1) &= f[\mathbf{X}(k), k] + \Gamma(k)\mathbf{W}(k) \\ \mathbf{Z}(k) &= h[\mathbf{X}(k), k] + \mathbf{V}(k) \end{aligned} \quad (4.1)$$

$\{\mathbf{W}(k)\}$  和  $\{\mathbf{V}(k)\}$  均为彼此不相关的零均值白噪声序列，且与初始状态也不相关，即对于  $k-1 \geq 0$  有

$$\begin{aligned} E[\mathbf{W}(k)] &= 0, E[\mathbf{W}(k)\mathbf{W}^T(l)] = \mathbf{Q}(k)\delta_{kl} \\ E[\mathbf{V}(k)] &= 0, E[\mathbf{V}(k)\mathbf{V}^T(l)] = \mathbf{R}(k)\delta_{kl} \\ E[\mathbf{W}(k)\mathbf{V}^T(l)] &= 0, E[\mathbf{X}(0)\mathbf{W}^T(k)] = 0, E[\mathbf{X}(0)\mathbf{V}^T(k)] = 0 \end{aligned}$$

初始状态为具有如下均值和方差(强度)阵的随机向量

$$E[\mathbf{X}(0)] = \mathbf{m}_0, \text{var}[\mathbf{X}(0)] = \mathbf{C}_0$$

$\mathbf{X}(k)$  是  $n$  维状态向量， $f[\mathbf{X}(k), k]$  是  $n$  维非线性离散函数。 $\Gamma(k)$  是  $n \times n$  矩阵， $h[\mathbf{X}(k), k]$  是  $m$  维非线性离散函数。

### 4.3.2 EKF 方法及其缺陷

对于线性系统，卡尔曼滤波在保证状态分布的前两阶矩（均值和协方差）的一致性上提供了最佳解决方法。卡尔曼滤波利用了以下事实：一是只给出一个分布的均值和方差（协方差），对此分布的最保守的假设是此分布为高斯分布，其均值和方差为给出的均值和方差；二是高斯分布经过线性运算后还是高斯分布。基于这两个假设，卡尔曼滤波给出了状态的均值和方差的最佳的可能估计。要求均值和方差是可测量的在实际应用中并没有困难，但是要求所有的量测和状态模型是线性的，在实际应用中是不现实的。为了将卡尔曼滤波应用到非线性情况，就产生了EKF。EKF不能说是卡尔曼滤波的完全推广，只是一个用线性去近似非线性的粗糙方法，EKF只是简单地将所有非线性模型线性化，然后再利用线性卡尔曼滤波方法，EKF给出的是最佳估计的一阶近似。EKF在实际使用中存在明显的缺陷<sup>[37]</sup>：一是线性化有可能产生极不稳定的滤波；二是EKF需计算雅可比矩阵的导数，这在多数情况下不是一件容易的事。

### 4.4 “无气味”卡尔曼滤波

自1993年以来，非线性滤波理论有了长足进展，涌现出诸如“粒子滤波”和“无气味”卡尔曼滤波（Unscented Kalman Filter, UKF）等处理强非线性系统的滤波方法，这给非线性多尺度理论研究提供了最基本的滤波工具。

UKF是一种递归的最小均方估计<sup>[10]</sup>。UKF不是估计观测和测量模型，而是估计出状态随机变量的分布。在UKF中状态随机变量的分布由高斯随机变量

(GRV) 表示, 并以最小数目的特定样本点描述该分布。这些特定的样本点可以准确描述GRV的均值和方差。对任何一个非线性系统采用UKF的方法, 可以获得精确到二阶的均值和方差。

由于UKF算法在处理非线性系统方面的优势, 本文将结合UKF方法来处理非线性状态估计的融合问题。UKF并不用线性化的方法去近似非线性状态方程或观测模型(要求模型噪声和量测噪声为高斯白噪声), 而是采用类似Monte Carlo仿真的思想。Monte Carlo方法就是用大量的实际粒子点来描述一个随机分布; 当我们需要知道某一个随机变量后验分布(一般无法直接得到), 只需要对这些粒子点进行相应(非)线性变换即可, 变换后的粒子点就可以用来描述后验分布。UKF算法是一种简化的Monte Carlo方法, 它不需要产生大量的粒子点, 只需要得到符合一定条件的粒子点。而这些粒子点表示的后验分布可以描述真实后验分布的二阶距, 而由EKF得到的后验变量的统计量只能描述后验分布的一阶项, 当系统非线性较强时, 其误差显而易见。

#### 4.4.1 UT 变换

UT变换是一种计算一个随机变量的非线性变换统计量的方法。假设  $X$  是一随机变量, 其均值  $\bar{X}$  的协方差  $P_x$ ,  $y$  是另一随机变量, 它同  $X$  成非线性关系,  $y = f(X)$ , 需要计算  $y$  的均值  $\bar{y}$  和协方差  $P_y$ 。

UT变换是选择一些点使得其样本均值和样本协方差分别为  $\bar{X}$  的  $P_x$ , 将这

些点中的每个点代入非线性函数得到变换后的点，而且  $\bar{y}$  和  $P_{yy}$  就是变换后的点的均值和协方差。

这里，先引入一个Sigma点分布的概念。均值为  $\bar{X}$  的协方差为  $P_{xx}$  的  $L$  维随机变量可以用  $2L+1$  个带有权值的Sigma点来近似的：

$$\begin{aligned} \chi_0 &= \bar{X}, W_0 = \lambda / (L + \lambda) \\ \chi_i &= \bar{X} + (\sqrt{(L + \lambda)P_{xx}})_i, i = 1, \dots, L \\ \chi_i &= \bar{X} - (\sqrt{(L + \lambda)P_{xx}})_i, i = L + 1, \dots, 2L \\ W_0^{(m)} &= 1 / 2(L + \lambda), \\ W_0^{(c)} &= 1 / 2(L + \lambda) + (1 - \alpha^2 + \beta), \\ W_i^{(m)} &= W_i^{(c)} = 1 / 2(L + \lambda), i = 1, \dots, 2L \end{aligned} \quad (4.2)$$

其中， $(\sqrt{(L + \lambda)P_{xx}})_i$  是矩阵  $(L + \lambda)P_{xx}$  的平方根矩阵的第  $i$  行或第  $i$  列， $W_i$  是第  $i$  点的权。变换过程如下：

(1) 将  $2L+1$  个sigma点代入非线性函数得到系列变换点  $Y_i = f(\chi_i)$ ；

(2) 求出变换点的均值是  $\bar{y} = \sum_{i=0}^{2L} W_i Y_i$ ；

(3) 求出这些变换点的协方差  $P_{yy} = \sum_{i=0}^{2L} W_i \{Y_i - \bar{y}\} \{Y_i - \bar{y}\}^T$ ；

此算法具有以下性质：

(1) 因为  $X$  的均值和协方差可以准确到二阶，这样  $y$  的均值和协方差的计算值也可以达到二阶，从这可以看出，UKF 的计算值的准确度比EKF要高，而协方差的准确度至少一样。

(2) 这些sigma点俘获到的均值和协方差不会因为不同的平方根方法而改变。因此可以采用效率高、数值稳定的Cholesky方法。

(3) 可用标准的向量和矩阵运算来计算均值和协方差，因不需计算EKF中需要计算的Jacobi矩阵，所以实现速度快。

以上均值和方差的估计精确到  $f(X)$  的Taylor展开的二次项。误差只会由三次以上高阶项引起。相对而言，EKF仅能够计算精确到一次项的均值及方差，并将所有高阶项忽略。详细证明见文献[36]。UT与EKF的性能比较见图4.1。




图 4.1 EKF 和 UKF 的比较

图4.1左边的图是用Monte Carlo方法得到的  $y$  的真实概率密度，即用5000个正态分布采样点通过强非线性函数后的得到的点来表示， $y$  的均值和方差都能通过这些点计算得到；右边的图表示UT方法得到的估计结果；均值的估计几乎是 unbiased 的，方差的估计与真实值也很接近。中间的图表示利用EKF得到的结



果，因为仅仅利用了一阶项计算得到的均值和方差的误差显而易见。

#### 4.4.2 UKF 算法

系统量测方程和状态方程为 (4.1)。将状态、状态噪声变量和测量噪声变量合成一个变量考虑，即：

$$\mathbf{X}_k^a = [\mathbf{X}_k^T \mathbf{W}_k^T \mathbf{V}_k^T]^T$$

对  $\mathbf{X}_k^a$  应用 UT 变换，得到  $\chi^a = [(\chi^x)^T (\chi^y)^T (\chi^z)^T]^T$ 。可得到 UKF 的计算公式如下：

(1) 初始化

$$\begin{aligned} \bar{\mathbf{X}}_0 &= E[\mathbf{X}_0] \\ \mathbf{P}_0 &= E[(\mathbf{X}_0 - \bar{\mathbf{X}}_0)(\mathbf{X}_0 - \bar{\mathbf{X}}_0)^T] \\ \bar{\mathbf{X}}_0^a &= E[\mathbf{X}_0^a] = [\bar{\mathbf{X}}_0^a \ 0 \ 0]^T \\ \mathbf{P}_0^a &= E[(\mathbf{X}_0^a - \bar{\mathbf{X}}_0^a)(\mathbf{X}_0^a - \bar{\mathbf{X}}_0^a)^T] = \begin{pmatrix} \mathbf{P}_0 & 0 & 0 \\ 0 & \mathbf{Q} & 0 \\ 0 & 0 & R \end{pmatrix} \end{aligned} \quad (4.3)$$

(2) 对任意  $k \in \{1, \dots, \infty\}$ ,

a. 计算 sigma 点：

$$\chi_{k-1}^a = [\bar{\mathbf{X}}_{k-1}^a \ \bar{\mathbf{X}}_{k-1}^a \pm \sqrt{(L + \lambda)\mathbf{P}_{k-1}^a}] \quad (4.4)$$

b. 时间更新：

$$\begin{aligned}
 \chi_{k|k-1}^x &= \Phi(\chi_{k-1}^x, \chi_{k-1}^y) \\
 \bar{\mathbf{X}}_{t|t-1} &= \sum_{i=0}^{2L} W_i^{(m)} \chi_{i,k|k-1}^x \\
 \mathbf{P}_{t|t-1} &= \sum_{i=0}^{2L} W_i^{(c)} [\chi_{i,k|k-1}^x - \bar{\mathbf{X}}_{k|k-1}] [\chi_{i,k|k-1}^x - \bar{\mathbf{X}}_{k|k-1}]^T \\
 \mathbf{Y}_{k/k-1} &= H(\chi_{k-1}^x, \chi_{k-1}^y) \\
 \bar{\mathbf{y}}_{k/k-1} &= \sum_{i=0}^{2L} W_i^{(m)} \mathbf{Y}_{i,k|k-1}
 \end{aligned} \tag{4.5}$$

### c. 量测更新

$$\begin{aligned}
 \mathbf{P}_{\bar{\mathbf{y}}_k \bar{\mathbf{y}}_k} &= \sum_{i=0}^{2L} W_i^{(c)} [\mathbf{Y}_{i,k|k-1} - \bar{\mathbf{y}}_{k/k-1}] [\mathbf{Y}_{i,k|k-1} - \bar{\mathbf{y}}_{k/k-1}]^T \\
 \mathbf{P}_{\mathbf{x}_k \mathbf{y}_k} &= \sum_{i=0}^{2L} W_i^{(c)} [\chi_{i,k|k-1}^x - \bar{\mathbf{X}}_{k|k-1}] [\mathbf{Y}_{i,k|k-1} - \bar{\mathbf{y}}_{k/k-1}]^T \\
 \mathbf{K}_k &= \mathbf{P}_{\mathbf{x}_k \mathbf{y}_k} \mathbf{P}_{\bar{\mathbf{y}}_k \bar{\mathbf{y}}_k}^{-1} \\
 \bar{\mathbf{X}}_k &= \bar{\mathbf{X}}_{k|k-1} + \mathbf{K}_k (\mathbf{y}_k - \bar{\mathbf{y}}_{k/k-1}) \\
 \mathbf{P}_k &= \mathbf{P}_{k|k-1} - \mathbf{K}_k \mathbf{P}_{\bar{\mathbf{y}}_k \bar{\mathbf{y}}_k} \mathbf{K}_k^T
 \end{aligned} \tag{4.6}$$

以上是UKF最简单的形式。它是在特殊情形下的算法，即模型噪声和量测噪声是加性噪声，噪声的协方差阵用简单的迭加过程就可以融合到状态方差阵当中。

## 4.5 基于 UKF 的多传感器数据融合算法

本章提出了一种基于 UKF 的多传感器数据融合算法。如图 4.2 所示，采用 UKF 滤波器组得到每一个传感器的状态及方差的估计值。由得到的方差的估计值，根据 (2.10) 可以估计出每个传感器的状态的权值，进而可以得到状

态的融合估计。




图 4.2 基于 UKF 的多传感器数据融合算法

#### 4.5.1 基于 UKF 的融合算法

考虑一个有  $N$  个传感器的非线性系统。非系统运动规律在离散化状态方程及测量方程的基础上可模拟为：

$$\begin{aligned} \mathbf{y}_k &= f(\mathbf{y}_{k-1}, \mathbf{u}_k, \mathbf{v}_k) \\ \mathbf{z}_k^m &= h(\mathbf{y}_k, \mathbf{w}_k^m) \quad m=1, \dots, N \end{aligned} \quad (4.7)$$

其中  $\mathbf{y}_k$  是  $k$  时刻的状态向量， $\mathbf{u}_k$  是  $k$  时刻的系统的输入向量， $\mathbf{v}_k$  是均值为  $E[\mathbf{v}_k]=0$  过程噪声， $\mathbf{z}_k^m$  是第  $m$  个传感器在  $k$  时刻的测量值， $\mathbf{w}_k^m$  是均值为  $E[\mathbf{w}_k^m]=0$  测量噪声。利用在测量过程中我们可以得到的测量值  $\mathbf{z}_k^m$  估计出每一个传感器的状态向量  $\mathbf{y}_k$ 。

对于多个传感器的状态的估计值可由以下的式子得到：

$$\hat{\mathbf{y}}_k = \sum_{m=1}^N \omega_k^m \bar{\mathbf{y}}_k^m \quad m=1, \dots, N \quad (4.8)$$

$\hat{\mathbf{y}}_k^m$  是对第  $m$  个传感器的状态向量的估计值,  $\hat{\mathbf{y}}_k$  是由  $N$  个传感器的状态的估计值得到的状态向量的融合值,  $\omega_k^m$  是  $\hat{\mathbf{y}}_k^m$  的权值, 且  $\sum_{m=1}^N \omega_k^m = 1$ 。

对每个传感器的测量数据采用 UKF 算法, 得到每个传感器的状态的估计值  $\hat{\mathbf{y}}_k^m$  及其方差  $\sigma_m^2$ , 然后根据第二章的公式 (2.10) 估计出权值  $\omega_k^m$ , 由 (4.8) 式可以得到融合的结果。

## 4.5.2 仿真及结果

设用多传感器测量的动态非线性模型如下<sup>[37]</sup>:

$$\begin{aligned} y_t &= 1 + \sin(0.04\pi t) + 0.5y_{t-1} + v_t \\ z_t^m &= \begin{cases} 0.2y_t^2 + w_t^m & t \leq 30 \\ 0.5y_t^2 - 2 + w_t^m & t > 30 \end{cases} \end{aligned}$$


其中, 采样的时间为  $T=1$ , 过程噪声  $v_t$  为均值为 0 方差为  $R$  的高斯噪声, 测量噪声  $w_t^m$  为均值为 0 方差为  $Q^m$  ( $m=1, 2, 3, 4$ ) 的高斯噪声。在我们的多传感器系统中, 采用 4 个传感器测量同一个过程, 假设每一个传感器受到不同的测量噪声的影响。为了说明测量噪声的大小, 信噪比 (SNR) 定义为:

$$SNR = 10 \lg \left( \frac{1}{Q^m} \right)$$

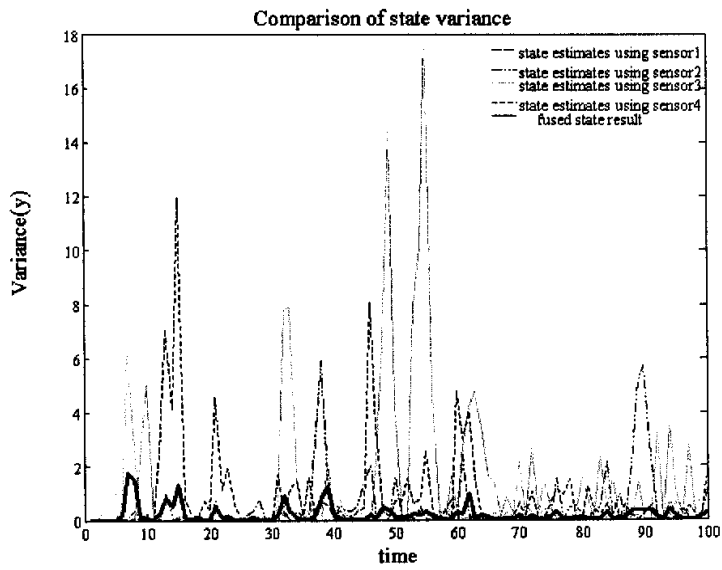
对于每一个传感器的测量值采用 UKF 滤波器, 得到状态的估计值  $\hat{\mathbf{y}}_k^m$  及

其方差；根据 UKF 估计出的每一个传感器的方差，由 (2.10) 式估计出每一个传感器的权值；最后由 (4.8) 式得到融合的结果  $\hat{\mathbf{y}}_k$ 。

如图 4.3 所示，(a) 图为每个传感器的状态的方差与  $\hat{\mathbf{y}}_k$  的方差比较，(b) 图为经过 UKF 滤波后得到的  $\hat{\mathbf{y}}_k^m$  的方差与融合结果  $\hat{\mathbf{y}}_k$  的方差比较。可见， $\hat{\mathbf{y}}_k$  的方差不仅小于每个传感器的状态的方差，而且小于  $\hat{\mathbf{y}}_k^m$  的方差。为了说明该算法的有效性，表 4.1 给出了三组在不同的测量噪声方差  $R$  下的仿真结果。 $\sigma_{\text{state}}^2$  为状态的方差， $\sigma_{\text{UKF}}^2$  为  $\hat{\mathbf{y}}_k^m$  的方差， $\sigma_{\text{fusion}}^2$  为  $\hat{\mathbf{y}}_k$  的方差。仿真结果表明， $\sigma_{\text{fusion}}^2$  不仅小于每一个  $\sigma_{\text{state}}^2$ ，而且小于每一个  $\sigma_{\text{UKF}}^2$ 。图 4.3 及表 4.1 的结果均表明该算法是有效的。



(a)



(b)

图 4.3方差比较

R	T	NO.	SNR	$\sigma_{\text{state}}^2$	$\sigma_{\text{UKF}}^2$	$\sigma_{\text{fusion}}^2$
10	1	1	7.5502	12.2135	0.4165	0.1096
		2	10.4982	14.0590	0.1217	
		3	7.9851	16.8347	0.1259	
		4	9.1629	9.9698	0.1866	
	2	1	-17.9176	14.9024	3.1313	0.6549
		2	-20.1490	13.6438	2.4866	
		3	-20.7944	12.2545	2.3048	
		4	-18.7180	9.2313	1.2895	
	3	1	-29.9573	14.0489	13.482	2.4328
		2	-27.0805	11.4172	5.9440	
		3	-28.9037	20.7270	11.790	
		4	-30.4452	11.8274	11.633	
20	1	1	6.9315	21.8606	0.0806	0.0528
		2	5.1083	36.5672	0.2229	
		3	7.9851	23.4947	0.1029	
		4	12.0397	24.3550	0.0258	
	2	1	-20.7944	28.6251	3.8869	1.3822
		2	-20.9186	22.4185	2.4660	
		3	-18.2455	22.5730	3.6119	
		4	-16.6771	35.4053	4.5610	
	3	1	-32.1888	23.0821	11.236	2.8669
		2	-33.3220	24.2393	8.5299	
		3	-34.1773	26.5907	10.819	
		4	-31.3549	22.7076	8.0714	
80	1	1	-16.0944	96.7657	4.7631	3.7495
		2	-17.0475	79.4645	8.9688	
		3	-17.5786	104.1121	5.6588	
		4	-18.7180	112.9728	5.6392	
	2	1	-32.1888	91.2431	10.109	7.4178
		2	-31.9867	112.0309	10.453	
		3	-33.3220	111.2676	22.070	
		4	-32.7714	109.6060	20.720	
	3	1	-40.0733	124.8413	10.857	8.0934
		2	-39.8898	62.4350	9.0770	
		3	-40.6044	106.2971	17.742	
		4	-41.7439	104.8898	26.757	

表 4.1 不同测量噪声下的方差比较

## 4.6 本章小结

为了得到状态的融合结果，本章提出了一种基于 UKF 的多传感器数据融合算法。分析结果表明 UKF 可以更好的估计出非线性系统的状态及其方差，在此基础上，在 MMSE 的意义上得到最优的融合结果。仿真结果表明该算法是有效的。



## 结论

由于多传感器系统较之单传感系统在估计性能上有很大优越性，近几年来，在工程和科学技术上越来越多地采用多传感器技术，这是多传感器融合技术产生的必然结果，因此多传感器融合技术具有广阔的发展前景。

本文主要研究了以加权的方式进行对同源多传感器进行数据融合的方法，即研究如何对每个传感器进行加权值，从而得到对被测参数最优估计的方法。为了从被噪声干扰的测量值中获得更准确的测量结果，本文首先提出了基于奇异值分解的数据融合算法，利用每个传感器测量值所对应的奇异值，估计出每个传感器的权值，从而在不要任何先验知识的条件下，仅由测量值得到对被测量的最优估计；为了得到被测量的分布信息，本文进一步提出了基于小波降噪和数据融合的传感器数据重建算法，并将此算法应用于实际的试验平台，得到了对各个传感器数据的更为准确的估计；最后结合非线性理论及数据融合理论，研究了多传感器加权 UKF，克服了 EKF 的缺点，得到状态融合估计。

对于多传感器数据融合还有很多问题有待继续研究，怎样将故障诊断与多传感器数据融合结合起来考虑，如何获得并排除多传感器系统中的故障信息都是有待继续研究的。

## 参考文献

1. 刘同明, 夏祖勋, 解洪成; “数据融合技术及其应用”; 北京, 国防工业出版社, 1998,9.
2. 何友, 王国宏, “多传感器信息融合及应用”, 北京, 电子工业出版社, 2000,11
3. Hall D L, Llinas J., “A survey of techniques for CIS data fusion”. *Proceedings of the Second International Conference Command, Control and Communications and Management Information System*. Boumemouth, UK, IEEE, London, April, 1987, pp77-84
4. Liu, L.J., Gu, Y.G., and J.Y. Yang, “Inference for Data Fusion”. *Neural and Stochastic Methods in Image and Signal Processing. Proceedings of the SPIE-The International Society for Optical Engineering*. 20-23 July 1992: San Diego, CA. SPIE, 1992, pp670-677.
5. Hoballah, I.Y. and P.K. Varshney, “Distributed Bayesian Signal Detection.” *IEEE Transactions on Information Theory*. Sept. 1989, pp995-1000.
6. S. Subramnian and M. Abdelrahman, “Intelligent Signal Validation for a Cupola Iron Melting Furnace”. *Presented at the American Control Conference*, CA, June 2-4, 1999
7. J. Folik, M. Abdelrahman and P. Kandasamy, “A confidence-based approach to the self-validation, fusion and reconstruction of quasi-redundant sensor data”. *IEEE Trans. Instrum. Meas.*, 50(6), 2001, pp1761-1769.
8. Haykin S., Yee P. and Derbez E., “Optimum nonlinear filtering”. *IEEE Transactions on Signal Processing*, 1997, 45(11), pp2774-2786
9. Kenneth S. Miller and Donald M. Leskiw, “Nonlinear estimation with radar observations”. *IEEE transactions on aerospace and electronic systems*. 1982, 18(2), pp192-200
10. S.J. Julier, J.K. Uhlmann, “A New Extension of the Kalman Filter to Nonlinear Systems”. In *Proc of AeroSense: The 11th Int. Symp. On Aerospace/Defense Sensing, Simulation and Controls*, 1997.
11. S. J. Julier, “A new method for the nonlinear transformation of means and covariance in filters and estimators”. *IEEE Trans. on Automatic Control*, pp.

- 477-482, Mar. 2000.
12. Eric A. Wan and Rudolph van der Menve, "The Unscented Kalman Filter for Nonlinear Estimation". *Proceedings of Symposium 2000 on Adaptive Systems for Signal Processing, Communication and Control (AS-SPCC)*, IEEE, Lake Louise, Alberta, Canada, Oct, 2000.
  13. E. A. Wan and R. van der Merwe, "Kalman Filtering and Neural Networks". Chapter 7: The Unscented Kalman Filter, (50 pages), *Wiley Publishing*, Eds. S. Haykin, 2001.
  14. R. van der Menve and E. A. Wan, "The Square-Root Unscented Kalman Filter for State and Parameter-Estimation". *International Conference on Acoustics, Speech, and Signal Processing*, Salt Lake City, Utah, May, 2001.
  15. B. Stenger, P. R. S. Mendonqa, and R. Cipolla, "Model-Based Hand Tracking Using an Unscented Kalman Filter". *Proc. British Machine Vision Conference (BMVC 2001)*, Volume I, pages 63-72, Manchester, UK, September, 2001
  16. James R. Van Zandt, "Boost Phase Tracking with an Unscented Filter". *Signal and Data Processing of Small Targets*, Proceedings of SPIE Vol. #4728, 2002.
  17. B. Horner, F. Mesch, A. Trachtler, "A multi-sensor induction flowmeter reducing errors due to nonaxisymmetric flow". *profiles. Meas. Sci. Technol*, 1996, 7, pp354~360
  18. J.A. Shercliff, "The theory of electromagnetic flow measurement". Cambridge, *The University Press*, 1962
  19. A. Yousif, Becker Roger, "Analysis of the performance of three large-electrode electromagnetic flowmeters". *J Phys. D: Appl. Phys.*, 1979, 12: 1423~1434
  20. 黄宝森, 孔昭育, 景永芳等, "电磁流量计", 北京, 原子能出版社, 1981.
  21. W. Engl. Der induktive Durchflussmesser mit inhomogenem magnetfeld. *Archiv fuer Elektrotechnik* 1970, 53: 344~359
  22. L.J. Xu, X.M. Li, F. Dong, Y. Wang and L.A. Xu, "Optimum estimation of the mean flow velocity for the multi-electrode inductance flowmeter". *Meas. Sci. Technol.*, 12 (2001) 1139-1146.
  23. 徐立军, 郝莹, 王亚等. 多对电极电磁流量测量方法的仿真研究. *东北大学学报(自然科学版)*, 2000, 21: 85~88
  24. G. H, 戈卢布, C.F.范洛恩, 矩阵计算p494-498, 科学出版社, 2001

25. Jhon Yen, Liang Wang, "Application of Statistical Information Criteria for Optimal Fuzzy Model Construction". *IEEE Transaction on Fuzzy System*, vol.6, No.3, August 1998
26. Yen and L. Wang, "An SVD-based fuzzy model reduction strategy". *Proc. 5th IEEE Int. Conf. Fuzzy Syst.*, New Orleans, LA, Sept. 1996, pp. 835-841.
27. Folik J, Abdelrahman M, Kandasamy P., "A confidence-based approach to the self-validation, fusion and reconstruction of quasi-redundant sensor data". *IEEE Trans. Instrum. Meas.*, 2001, 50(6): 1761-1769.
28. 杨力华, 戴道清, 黄文良等译, "信号处理的小波引导", 北京: 机械工业出版社, 2002
29. Stein C., "Estimation of the mean of a multivariate normal distribution". *Annals of statistics*, 1981, 11(9): 1135-1151
30. Chong, C.Y., Chang, K. C. and Mori, S., "Distributed tracking in the distributed sensor networks". *Proceedings of the American control conference, Seattle*, 1986.
31. Chong, C.Y., Mori, S and Chang, K. C., "Distributed multitarget multisensor tracking". Y. Bar-Shalom (Ed.), *multitarget-Multisensor tracking: Applications and Advances*, Vol. I. Dedham, MA: Artech House, 1990, ch.8.
32. Bar-Shalom, Y., "On the track-to-track correlation problem". *IEEE Transactions on Automatic control*, AC-26, 2 (1981), 571-572
33. Bar-Shalom, Y., and Campo, L., "The effect of the common process noise on the two-sensor fused-track covariance". *IEEE Transactions on Aerospace and Electronic Systems*, AES-22, 6 (1986), 803-804
34. Saha, R. K., "Track-to track fusion with dissimilar sensors". *IEEE Transactions on Aerospace and Electronic Systems*, 32, 3 (1996), pp 1021-1029
35. Anderson, B.D.and Moore, J.B., "Optimal Filtering". *Prentice-Hall*, New Jersey.
36. J. Julier and J. K. Uhlmann, "A General Method for Approximating Nonlinear Transformations of Probability Distributions". *Technical Report*, Robotics Research Group, Department of Engineering Science, University of Oxford, 1996
37. Rudolph van der Merwe, Arnaud Doucet, Nando de Freitas and Eric Wan, "The unscented particle filter". *Technical Report CUED/F-INFENG/TR 380*, Cambridge University Engineering Department, August 16, 2000

## 攻读学位期间发表的学术论文

- [1] 杨惠娟、张建秋, “一种基于奇异值分解的动态多传感器数据融合算法”, 《传感技术学报》, 2004 年, 17 卷, 第 3 期, pp440-446
- [2] 杨惠娟、张建秋, “基于小波去噪和数据融合的多传感器数据重建算法”, 《复旦学报 (自然科学版)》, 2005 年, 44 卷, 第 1 期, pp161-165
- [3] Huijuan Yang, Jian Qiu Zhang. “An unscented Kalman Filter-Based multisensor track fusion algorithm”. IEEE IMTC, May, 2005. Accepted.

## 致谢

首先我要感谢我的导师张建秋教授。本文的总体思想和每一项研究的成果都离不开张老师的悉心指导和有益的启发。我很庆幸在复旦的三年中能遇到这样一位知识渊博，而又平易近人的导师。感谢张老师在我的研究生阶段在生活及其它各方面的给予的关心和帮助。

同时要感谢胡波教授，在胡老师的指导下，使我在做科研项目过程中学到了很多知识，增长了一定的经验。还要感谢张立明教授，在云南大学初次聆听张老师讲课时就被张老师的对科学事业的非凡热忱与智慧深深地打动，在三年的研究生学习中张老师也给了我很多的建议和指导。

研究生三年中，我们的实验室从无到有，从只有我一个学生到现在近十几名学生，我对实验室的总存有一份深深感情，实验室的每一个人如同我的兄弟姐妹。感谢实验室的师妹、师弟让我感受到实验室的团结和睦、积极向上。感谢他们每一个人，是他们使实验室成为了一个有内涵，有创造力、活泼的集体。感谢高羽，在我论文的编辑过程中给予我很多的建议和帮助。

感谢我的父母不仅赋予我生命、教诲我生活的哲理，而且他们是我不断向前的动力源泉。感谢我的族人，作为纳西族的一分子，是玉龙雪山给了我勇气，是民族的自豪感和自信心让我始终坚持永不放弃的信念。不过，我做的还远远不够。相信通过接下来的博士研究生的学习，三年后的今天我会交一份更好的答卷。

## 论文独创性声明

本论文是我个人在导师指导下进行的研究工作及取得的研究成果。论文中除了特别加以标注和致谢的地方外，不包含其他人或其它机构已经发表或撰写过的研究成果。其他同志对本研究的启发和所做的贡献均已在论文中作了明确的声明并表示了谢意。

作者签名: 杨惠娟 日期: 2005.6.1

## 论文使用授权声明

本人完全了解复旦大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其它复制手段保存论文。保密的论文在解密后遵守此规定。

作者签名: 杨惠娟 导师签名: 张树东 日期: 2005.6.1